https://hjfy.top/arxiv/2610.31667v1

直接传递 @k 最优化用于思维 剪枝： 在测试时推理中平衡质量与多样性

Mahdi Salmani, Adel Javanmard, Devansh Gupta, and Meisam Razaviyayn

University of Southern California
{salmanis, ajavanma, guptadev, razaviya}@usc.edu

摘要

测试时缩放已成为推理模型的关键推理策略，其中模型生成大量候选解，以期找到至少一个正确解。运行所有候选解直至完成可能计算开销较大，因此近期工作在仅生成较短前缀后对候选池进行剪枝，仅对留存的候选解继续执行后续计算。现有的剪枝策略大致可分为两类：基于质量的方法为每个部分解分配得分，并丢弃那些预测最终将导致错误解的部分解；基于多样性的方法则选择遵循不同推理路径的部分解，从而更有可能覆盖不同的最终解。这两类目标之间的权衡是探索与利用之间权衡的一个实例，然而迄今为止极少甚至没有先前的工作直接揭示这一权衡，更不用说对其进行优化。在本文中，我们提出一种剪枝过程，通过在所选解池上优化 pass@k 直接解决这一权衡问题。具体而言，该方法选择解池以最大化至少一个部分解在继续生成至完成时产生正确答案的概率。由于该目标同时奖励高质量的部分解并惩罚它们之间的冗余性，因此质量与多样性由准则本身自然平衡，而非通过分离的、临时的设计选择实现。在八种开放权重推理模型上，我们的方法优于现有的基于质量与基于多样性的剪枝策略。当剪枝过程保留适中数量的部分解以继续生成时，性能提升尤为显著，凸显了在剪枝过程中直接平衡质量与多样性的价值。

1 引言

大语言模型（LLMs）在复杂推理任务中展现了卓越的能力，表现出解决需要多步逻辑的复杂问题的强大潜力 [15, 18, 21, 45, 52]。为了进一步提升这些能力，测试时缩放（test-time scaling）已成为一种突出的策略，通过为单个问题生成多个候选解，使模型能够探索多样化的推理策略，并显著提升最终性能 [3, 35, 44, 48]. 然而，测试时计算资源的缩放面临一个重大挑战：生成大量完整解的成本极高，我们后续将此类过程称为 *rollouts* [23, 33]。除了生成过程外，在 best-of-N 方法中对已完成的 rollouts 进行评估也存在高昂成本，即使用奖励模型对每个 rollout 进行评分，这在大规模长推理迹上计算开销巨大 [11, 26, 36]。生成与在 best-of-N 方法中评估所有 N rollouts 所带来的计算瓶颈，要求在部分 rollouts 达到最终答案并终止前进行测试时剪枝。换句话说，我们仅将所有 N rollouts 生成至 T token 的截止长度，保留其中最具有前景的 k 个，并将其运行至完整的 token 预算 B，如 Fig. 1 所示。

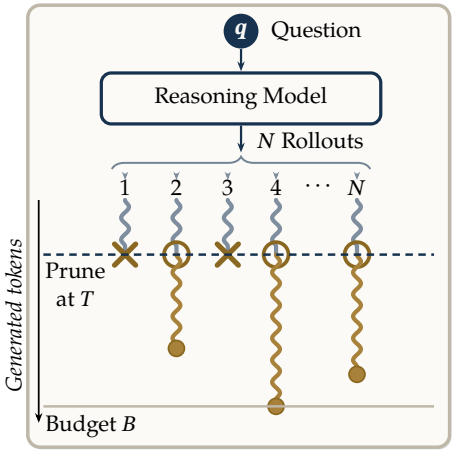


图 1: **测试时剪枝**。只有 k 个 N 个回溯（环形标记）能超过截止点 T ，直至达到预算 B 。

一类方法考察模型在生成过程中的置信度动态变化，利用诸如 Logit 熵或置信度等指标 [17, 30, 43, 50]。其潜在直觉在于：如果模型在中间解码步骤中过于自信，则继续推理过程是计算资源的浪费；反之，若模型完全缺乏置信度，无论提供多少额外计算，也难以得到正确解，因此可以提前终止。另一类工作则利用模型的内部状态，特别是其 Transformer 块的隐状态，来识别哪些轨迹值得继续 [1, 54]。通过“探测”这些内部状态，可以预测模型最终是否能得出正确答案，从而将剪枝问题转化为一个分类任务。这使得那些不太可能产生正确最终答案的部分轨迹能够被提前丢弃。与此同时，另一条研究路径优先考虑表示探索（RepExp），以选择一组覆盖尽可能多不同推理策略的轨迹子集 [39]。通过选取对应嵌入差异较大的部分轨迹，RepExp 旨在探索多样化的推理路径。

然而，这些方法位于一个光谱的两端，且均未直接优化我们真正关心的数量。探测方法的问题在于，它们排名最高的轨迹往往彼此相似。因此，探测器可能同时对所有保留的轨迹都做出自信的错误判断，而没有任何一条轨迹能得出正确答案。这是纯粹利用（Fig. 2a）的问题。另一方面，RepExp 虽然能找到多样化的轨迹，但由于忽略了轨迹的质量，它可能会将大量预算花费在极不可能成功的轨迹上（Fig. 2b）。这些局限性促使我们采用实际希望优化的度量来选择轨迹，即选择一组 S 个 k 的轨迹，以最大化 pass@k ，也就是 $\max_{|S|=k} \text{pass@}k(S)$，我们在 Eq. 3 中对此进行了形式化。直接优化这一目标可确保所选轨迹具有足够的多样性，避免共同失败，同时仍倾向于高质量的轨迹（Fig. 2c）。

为此，我们提出 **PKTP** (**P**ass@$\boldsymbol{k}$ **T**hought **P**runing)，一种通过直接最大化 pass@k 来选择保留轨迹的剪枝框架。主要难点在于，即使轨迹是独立采样的，其结果在给定轨迹的部分观测条件下也并非独立（即，具有相似部分轨迹的轨迹往往同时成功或失败）。因此，pass@k 依赖于它们的联合分布。我们采用一个潜在高斯模型来建模这种联合分布，其中每条轨迹的正确性由对高斯得分进行阈值处理得到。在该模型下评估 pass@k 需要对潜变量进行期望计算，因此我们推导出其闭式二阶近似。我们证明该近似具有次模性，从而可使用贪心算法近似求解，以找到大小为 k 的子集。该框架的一个重要特点是，潜变量模型仅需训练一次，且不依赖于 k，单次贪心遍历即可生成嵌套的子集序列，因此推理时可在线选择预算 k 而无需重新训练。

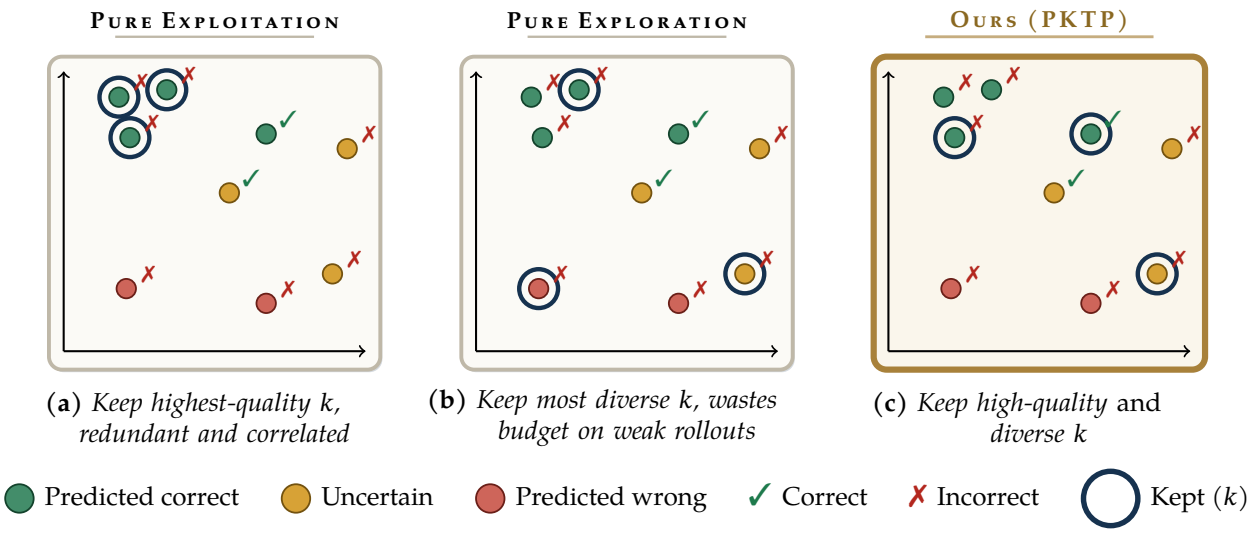


图 2: **概念示意图**。相同的候选回溯序列池，根据其部分回溯序列的嵌入表示在嵌入空间中的位置，展示三种剪枝策略。每个回溯序列按其预测正确性着色，并以✓/✗标记其实际结果；被 $k = 3$ 保留的回溯序列用圆环标出。**(a) 纯利用**保留得分最高的回溯序列，但它们相关性强且聚集在一起，因此错失了正确的回溯序列。**(b) 纯探索**保留一个最大化多样性子集，但将预算花费在低质量回溯序列上，同样错失了正确回溯序列。**(c) 我们的方法**在保留子集上直接优化 pass@k ，平衡质量与多样性，成功保留下了正确的回溯序列。

贡献。　首先，我们将剪枝问题建模为最大化保留集合的 pass@k ，同时我们对不同回溯路径共同失败的相似性进行建模。其次，我们推导出 pass@k 的闭式、子模近似，该近似将探测与 RepExp 联系起来。第三，通过对八种推理模型的实验表明，PKTP 在现有剪枝方法基础上有所改进，尤其在 k 取中等值时表现更优。

2　问题表述与相关工作

设置　给定一个问题 $\boldsymbol{q}$，我们从模型 π 中抽取 N 个候选推理轨迹 $y^{(i)} \sim \pi(\cdot \mid \boldsymbol{q})$。每个轨迹仅通过其前 T 个 token（即前缀 $y^{(i)}_{1:T}$）进行观察。我们将该前缀编码为一个表示向量 $h_i = h\left(y^{(i)}_{1:T}\right)$，即推理至第 T 个 token 时的隐藏状态嵌入。随后进行剪枝，保留 $k \le N$ 个轨迹，将其运行至完整的 token 预算 B，其余则被丢弃。一个完成的轨迹 $y_{1:B}$ 要么正确，要么不正确，由符号 $C(y_{1:B}) \in \{-1, +1\}$ 记录。

$$C(y_{1:B}) \;=\; \begin{cases} +1, & \text{if } \textsc{Verify}(y_{1:B}), \\ -1, & \text{otherwise.} \end{cases} \tag{1}$$

此处 Verify 是一个 *任务特定的检查器*，当完成的轨迹达到正确的最终答案时返回真值，例如通过在数学问题上匹配参考解答或在编码任务上通过单元测试。我们用 $C(y^{(i)})$ 表示在运行至预算 B 后，第 i 次轨迹的结果。

表示。 为了剪枝部分轨迹，我们需要将每个前缀映射到一个能够捕捉其关键信息的向量。一类工作依赖于轨迹的手工设计特征以及模型的内部状态，例如 token 置信度、隐状态轨迹的几何结构或中间答案的收敛性。这些特征通常维度非常低 [13, 19, 28, 38, 40]。另一类工作则保留 Transformer 的隐状态，并将其池化为单个向量 [29, 39, 42]，我们采用的是这一类方法。具体而言，我们令 h_i 为隐状态的指数移动平均（EMA），该操作已被证明是一种有效的池化方式 [29]。因此，我们的改进是在这类嵌入表示上展示的，尽管我们的框架也可适用于其他嵌入表示。Appendix F 给出了我们所使用的表示的详细信息。

目标。 剪枝时，结果 $C(y^{(i)})$ 仍然未知，因为每个结果都依赖于我们尚未生成的（随机）延续。那么，我们该如何选择保留的 $|S| = k$ 次模拟 $S \subseteq \{1, \ldots, N\}$ 呢？有两种极端的选择如下。

(i) **(纯粹的利用)** 保留 S 中预测成功率最高的 $\{i\}$ 条模拟 $\mathbb{P}\big(C(y^{(i)}) = +1 \mid \boldsymbol{q}, y^{(i)}_{1:T}\big)$，这些成功率由在表示 h_i [54] 上训练的线性探测器估计，即对于学成的权值向量 w，得分 $w^\top h_i$ 最大的 k 条模拟。我们将这种剪枝策略称为 **线性探测**。

(ii) **(纯探索)** 构建一个多样化的 S，从随机回溯开始，通过求解贪婪地将回溯 $i^\star$ 添加到 S 中。

$$i^\star = \arg\max_{i \notin S} \; h_i^\top \Big(\tau I + \sum_{j \in S} h_j h_j^\top\Big)^{-1} h_i, \tag{2}$$

也就是说，我们添加那些表示中最少被已选中的表示所解释的轨迹，其中 $\tau > 0$ 是一个正则化项。这是 **RepExp** 剪枝策略 [39]。

极端的平衡无法兼顾质量与多样性。我们真正需要的是具有最佳 pass@k 的 k 组回溯。从数学上讲，我们寻求的是最有可能包含正确回溯的集合 S。

Pass@k Pruning Objective

$$\max_{S \subseteq \{1,\ldots,N\}} \mathbb{P}\left(\sum_{i \in S} \mathbf{1}\{C(y^{(i)}) = +1\} \;\geq\; 1 \;\middle|\; \boldsymbol{q}, y^{(1)}_{1:T}, \ldots, y^{(N)}_{1:T} \right) \quad \text{s.t.} \quad |S| = k. \tag{3}$$

此处，$\mathbf{1}\{\cdot\}$ 为指示函数，即 $\mathbf{1}\{True\} = 1$ 且 $\mathbf{1}\{False\} = 0$。Eq. 3 中的目标恰好是保留池中 pass@k 的确切概率，即一旦将至少一个存活的回溯路径运行至预算 B，便能获得正确答案的概率。我们还假设最终结果为二元的，尽管相同的方法可泛化至连续结果的情形，其中每个完成的回溯路径由奖励模型进行评分，目标是最大化保留回溯路径中的最佳得分 [10]，此时 Eq. 3 变为最大值 @k 目标 [41]。

相关工作 现有的剪枝方法对每个回溯路径单独评分，使用模型的置信度 [13, 30]、奖励模型 [36]，或对其隐状态的探测 [25, 54]，或者选择一组多样化的路径，如 RepExp 所做 [39]。Pass@k 也已被用作推理模型的训练目标 [8, 41]，但尚未用于决定保留哪些部分回溯路径。在语言模型之外，选择一组路径使得至少有一个成功的问题已在信息检索和贝叶斯优化中被研究过 [6, 34, 46]。Appendix G 提供了更详细的讨论。接下来，我们将讨论如何解决此类目标。

3 方法

求解 Eq. 3 存在一些挑战：首先，我们需要获得给定一组轨迹的 pass@k 。我们通过在概率模型下学习轨迹结果的联合分布来解决这一问题，从而可以估计任意一组轨迹的 pass@k 。其次，即使有了这种估计，寻找具有最高估计 pass@k 的 k 条轨迹子集仍是一个混合整数规划问题。因此，我们的框架可视为两个部分：学习结果的联合分布 (Section 3.1)，以及在选择时刻求解该混合整数规划问题 (Section 3.2)。

3.1 概率模型

Let $H = [h_1, \ldots, h_N] \in \mathbb{R}^{d\times N}$ collect the representations of the N generated partial rollouts, $Q_\theta : \mathbb{R}^d \to \mathbb{R}$ be a learnable mapping predicting the rollout quality, and define $Q_\theta(H) = [q_1, \ldots, q_N]^\top$ with $q_i := Q_\theta(h_i)$. We model the latent scores of the rollouts as

$$\mathbf{Z} = \underbrace{Q_\theta(H)}_{\text{Rollout Quality}} + \underbrace{H^\top \mathbf{f}}_{\text{Rollouts Correlation}} + \underbrace{\mathbf{m}}_{\text{Outcome Noise}}, \qquad \mathbf{m} \sim \mathcal{N}(0, I_N), \quad \mathbf{f} \sim \mathcal{N}(0, I_d), \tag{4}$$

其中 $\mathbf{m}$ 和 $\mathbf{f}$ 是独立的。直观上，$\mathbf{Z}_i$ 表示的是轨迹 i 的潜力得分，因此其质量 q_i 越高，得分也越高。在 q_i 的基础上，项 $h_i^\top \mathbf{f}$ 是具有相似表示的轨迹所共有的随机效应，这使得它们会一起成功或失败。事实上，对于不同的轨迹，$\mathrm{Cov}(\mathbf{Z}_i, \mathbf{Z}_j \mid H) = h_i^\top h_j$ ，因此具有对齐 h_i 的轨迹其结果呈正相关。最后，$\mathbf{m}_i$ 是特定于轨迹 i 的噪声。

回滚 i 的正确性 $C(y^{(i)})$ 通过将其得分在零处进行阈值处理来建模。更具体地，我们定义随机变量 $\mathbf{C}_i = 2 \times \mathbf{1}\{\mathbf{Z}_i \geq 0\} - 1$ 。换句话说，正得分意味着回滚是正确的，而负得分则意味着它是错误的。由于在给定 $\mathbf{f}$ 条件下得分相互独立，因此观测到的正确性模式 $c \in \{-1, 1\}^N$ 的似然为

$$\Pr\big[\mathbf{C} = c \mid H\big] = \mathbb{E}_{\mathbf{f}}\Big[\prod_{i=1}^{N} \Phi\big(c_i(q_i + h_i^\top \mathbf{f})\big)\Big], \tag{5}$$

where Φ is the standard Gaussian CDF, and the derivation can be found in Appendix A.1.

假设我们有 M 个训练问题，其中问题 m 包含一个数据池的表示 $H^{(m)}$ 及其观测结果 $c^{(m)} \in \{-1, 1\}^N$。映射 Q_θ 通过在 Eq. 5 条件下最大化其似然来训练，即通过求解

$$\max_\theta \ \frac{1}{M} \sum_{m=1}^{M} \log \Pr_\theta\big[\mathbf{C} = c^{(m)} \mid H^{(m)}\big], \tag{6}$$

其中 $\Pr_\theta$ 是在 Eq. 5 与 $H = H^{(m)} = [h_1^{(m)}, \ldots, h_N^{(m)}]$ 和 $q_i = Q_\theta(h_i^{(m)})$ 条件下的似然。直接求解 Eq. 6 很困难，因为 Eq. 5 中对 $\mathbf{f}$ 的期望没有确切的闭式解。因此，我们将每个对数因子在 $h_i^\top \mathbf{f}$ 上展开到二阶，这使得期望变为一个可以确切求解的高斯积分 (Theorem 1)。

Theorem 1 (Second-order surrogate)**.** 对于模式 $c \in \{-1,1\}^N$，令 ϕ 为标准正态密度，$\lambda_i(c_i) = \phi(q_i)/\Phi(c_i q_i)$，$\kappa_i(c_i) = \lambda_i(c_i)\big(\lambda_i(c_i) + c_i q_i\big)$，

$$\Sigma(c) = \sum_{i=1}^{N} \kappa_i(c_i)\, h_i h_i^\top, \qquad b(c) = \sum_{i=1}^{N} c_i \lambda_i(c_i)\, h_i. \tag{7}$$

然后，如 $\varepsilon \to 0$ 所示，

$$\log \Phi\big(c_i(q_i + \varepsilon)\big) = \log \Phi(c_i q_i) + c_i \lambda_i(c_i)\, \varepsilon - \frac{\kappa_i(c_i)}{2}\varepsilon^2 + O(|\varepsilon|^3), \tag{8}$$

并将 *Eq. 5* 中每个 $\Pr[\mathbf{C} = c \mid H]$ 的对数因子替换为在 $\varepsilon = h_i^\top \mathbf{f}$ 处的展开式，得到

$$\widetilde{\Pr}[\mathbf{C} = c \mid H] = \Big(\prod_{i=1}^{N} \Phi(c_i q_i)\Big) \det\big(I_d + \Sigma(c)\big)^{-1/2} \exp\Big(\frac{1}{2}\, b(c)^\top \big(I_d + \Sigma(c)\big)^{-1} b(c)\Big). \tag{9}$$

证明见 Appendix B.1.1。展开是局部的，因此我们使用 Eq. 9 作为易处理的替代，而不是确切恒等式或界。因此，我们将 $\Pr_\theta$ 在 Eq. 6 中替换为 $\widetilde{\Pr}_\theta$。

与其在相关系数项中直接使用 h_i，可以学习一个表示的编码器 $\mathcal{E}_\psi$，并用 $\mathcal{E}_\psi(h_i)$ 代替，但其有效性取决于数据量。由于我们的数据有限，我们保持 h_i 固定，从而使 Q_θ 成为唯一学成的组件；出于同样原因，我们对 Q_θ 采用简单的线性模型 $Q_\theta(h) = \theta^\top h + \theta_0$，如线性探针 [54] 所示。与分别针对每个轨迹正确性进行训练的线性探针不同，Q_θ 在一个问题的所有轨迹的联合结果上进行训练，因此其所学质量已考虑了它们之间的相关性。由于 Eq. 9 关于 θ 是闭式且可微的，我们通过在训练问题上的随机梯度上升来最大化代理似然。

3.2 子集选择

在 Eq. 3 中最大化 pass@k 等价于最小化所有保留的回溯路径全部失败的概率。在潜在高斯模型下，并忽略对 H 的条件依赖，一组保留的回溯路径 S 的失败概率为

$$L(S) = \Pr\big[\mathbf{C}_i = -1 \ \forall i \in S\big] = \mathbb{E}_{\mathbf{f}\sim\mathcal{N}(0,I_d)}\Big[\prod_{i\in S} \Phi\big(-(q_i + h_i^\top \mathbf{f})\big)\Big], \tag{10}$$

我们寻求使该值最小的一组 k 采样路径。由于 $L(S)$ 无闭式解，我们用 Theorem 1 进行近似。

Corollary 1 (Selection surrogate)**.** 对于集合 $S \subseteq [N] := \{1,\dots,N\}$，设 $\lambda_i = \phi(q_i)/\Phi(-q_i)$，$\kappa_i = \lambda_i(\lambda_i - q_i)$，$\Sigma_S = \sum_{i\in S} \kappa_i\, h_i h_i^\top$ 以及 $b_S = \sum_{i\in S} \lambda_i\, h_i$。对 S 中的回溯结果应用 *Theorem 1*，并对每个 $i \in S$ 采用 $c_i = -1$，可得到 $L(S)$ 的代理函数 $\widetilde{L}(S)$，满足

$$\log \widetilde{L}(S) = \underbrace{\sum_{i\in S} \log \Phi(-q_i)}_{\text{Rollout Quality}} + \underbrace{\Big(-\frac{1}{2}\log\det(I_d + \Sigma_S) + \frac{1}{2}\, b_S^\top (I_d + \Sigma_S)^{-1} b_S\Big)}_{\text{Rollouts Correlation}}. \tag{11}$$

证明见 Appendix B.1.2。因此，我们在 $|S| = k$ 上最小化 $\log \widetilde{L}(S)$。Eq. 11 的每一项都有直接的解释。第一项倾向于较大的 q_i，因为基准失败因子 $\Phi(-q_i)$ 随 q_i 增大而减小。负对数行列式奖励

一组覆盖多个方向的 h_i，而非反复选择同一方向。最后一项非负，惩罚加权向量 $\lambda_i h_i$ 朝同一方向叠加的情况，因为行列式本身无法检测此类情况，它对 h_i 和 $-h_i$ 一视同仁。例如，相同质量的两次回溯在 $h_2 = h_1$ 下比在 $h_2 = -h_1$ 下更常同时失败，但两种情况下 Σ_S 相同，因而行列式也相同，而 b_S 在第一种情况下为 $2\lambda_1 h_1$，第二种情况下为 0。

然而，精确地最小化 $\log \widetilde{L}(S)$ 是困难的。

Proposition 1 (Hardness of exact selection)**.** *在所有满足 $|S| = k$ 的 $S \subseteq [N]$ 中最小化 $\log \widetilde{L}(S)$ 是 NP-难的。*

证明见Appendix B.3，通过从最大独立集问题的归约得到。然而，当目标函数为单调且子模时，每次添加一个回溯路径的贪心优化器可保证达到最优值的至少 $(1 - e^{-1})$ 分数 [32]。确切的传递概率 $P(S) := 1 - L(S)$ 已被证明是单调且子模的 [46]。尽管子模函数的近似不一定保持子模性，但我们证明其代理函数 $\widetilde{P}(S) := 1 - \widetilde{L}(S)$ 同样具有单调性和子模性，因此贪心优化器及其近似保证适用于我们的问题。

Theorem 2 (Greedy guarantee)**.** *$\widetilde{P}$ is normalized ($\widetilde{P}(\varnothing) = 0$), monotone ($\widetilde{P}(A) \le \widetilde{P}(B)$ whenever $A \subseteq B$), and submodular, that is, for all $A \subseteq B \subseteq [N]$ and $j \notin B$,*

$$\widetilde{P}(A \cup \{j\}) - \widetilde{P}(A) \ge \widetilde{P}(B \cup \{j\}) - \widetilde{P}(B). \tag{12}$$

因此，通过重复添加 k 次、使得 $\widetilde{P}$ 增加最多的候选元素所得到的集合 S_k^{greedy} 满足

$$\widetilde{P}(S_k^{\text{greedy}}) \ge (1 - e^{-1}) \max_{|S| \le k} \widetilde{P}(S). \tag{13}$$

证明见Appendix B.2。

贪婪最优化。 The greedy optimizer starts from the empty set and, at each step, adds the candidate $j \notin S$ with the smallest change $\Delta_j(S) = \log \widetilde{L}(S \cup \{j\}) - \log \widetilde{L}(S)$. Since adding a candidate changes Σ_S by a rank-one matrix, this change has a closed form that can be updated cheaply without rebuilding the determinant and the inverse (Appendix A.2). With these rank-one updates, the greedy optimizer costs $O\big(k(Nd + d^2)\big)$ time and $O(Nd + d^2)$ memory. By comparison, a naive implementation that rebuilds and factorizes $I_d + \Sigma_{S \cup \{j\}}$ for every candidate costs $O(d^3)$ per candidate, that is, $O(kNd^3)$ time, with the same $O(Nd + d^2)$ memory.

3.3 与线性探测和 RepExp 的关系

代理模型使质量—多样性权衡显式化，并在极限情况下与两个基准准则相联系。如果在 Eq. 11 中关闭相关系数项，则 $\log \widetilde{L}(S) = \sum_{i \in S} \log \Phi(-q_i)$ ，因此最小化它将保持 k 的最大质量得分，恢复仅考虑质量的探测式排序；当 Q_θ 为相应的线性探测时，其与线性探测一致。在另一极端情况下，假设质量得分相等且罚项在整个选择过程中可忽略不计，则每个 κ_i 等于一个共同值 κ ，因此

$\Sigma_S = \kappa \sum_{i \in S} h_i h_i^\top$ ，相关的集合依赖项为 $-\frac{1}{2}\log\det(I_d + \Sigma_S)$ 。根据矩阵行列式引理，其贪婪的边际秩通过 j 评估候选者 $h_j^\top (I_d + \Sigma_S)^{-1} h_j$ ，即 RepExp 在相同表示下所使用的残差方差准则（详见 Appendix A.3 的推导）。在这两个极限之间，模块化质量、对数行列式多样性及罚项共同决定了所选集合。

上述两种极端情况并未展示当 k 增大时，PKTP 如何从线性探针（Linear Probe）过渡到 RepExp。为了观察这一过程，我们展开 $\log L(S)$ 及其近似形式，当相关系数较弱时的情况。

Proposition 2 (Weak correlations)**.** 修正 S、q_i 和 h_i，$\boxed{\mathrm{F}}$将 $\mathbf{f}$ 替$\boxed{\mathrm{F}}\boxed{\mathrm{F}}$ $\rho\mathbf{f}$。至於 $\rho \to 0$，

$$\log L(S) = \sum_{i \in S} \Big[\log \Phi(-q_i) + \tfrac{\rho^2}{2} \lambda_i q_i \|h_i\|^2 \Big] + \rho^2 \sum_{i<j \in S} \lambda_i \lambda_j \, h_i^\top h_j + O(\rho^4), \tag{14}$$

且 $\log \widetilde{L}(S)$ 的展开结果相同。

Proposition 2 展示了相关系数 ρ 如何控制 PKTP 在两个基准之间的位置。在 $\rho = 0$ 时，采样路径相互独立，扩展退化为 $\sum_{i \in S} \log \Phi(-q_i)$，PKTP 按质量对采样路径进行排序，如同线性探测（Linear Probe）一样。对于 $\rho > 0$，每一对保留的采样路径都会增加一个惩罚项 $\rho^2 \lambda_i \lambda_j h_i^\top h_j$，当它们的表示相似时，该惩罚项较大。向一组包含 t 个采样路径的集合中添加一条新路径，将支付 t 个此类惩罚，因此首个选择仅由质量决定，随着集合增大，惩罚累积，最终超过质量差异的影响，此后 PKTP 开始分散其选择，如同 RepExp 所做。ρ 越大，这一情况发生得越早，因此 ρ 决定了随着 k 增长，PKTP 从线性探测（Linear Probe）过渡到 RepExp 的速度。

Appendix C 使得该行为在固定 ρ 时两端精确。在小的 k 时，若第 k 个与第 $(k+1)$ 个最大质量之间的差距超过 $k\rho^2$ 的常数倍，PKTP 会精确保留具有最大 q_i 的 k 个候选者，且顺序与线性探测（Linear Probe）一致，当这一条件在每个预算不超过 k 时均成立。在大的 k 时，当少数高质量候选者从大量低质量候选者中脱颖而出，PKTP 的目标（平均化批量质量后）简化为 RepExp 目标加上这些突出候选者的额外项。因此，其极小化器会保留这些候选者，并几乎最大化 RepExp 目标。最后，这两个结果的条件并不冲突。我们构造了一个单一模型，采用一种质量分布和一个 ρ 值，使得在小的 k 时 PKTP 表现如同线性探测，而随着 k 增大，其平均目标趋于 RepExp 目标。

4 实验

4.1 设置

模型 我们在两个尺寸层级的八款开源权重推理模型上进行评估。小型层级包括 Qwen3-0.6B、Qwen3-1.7B [49]、OpenMath-Nemotron-1.5B [31] 以及 DeepSeek-R1-Distill-Qwen-1.5B [15]；大型层级包括 Qwen3-8B、OpenMath-Nemotron-7B、DeepSeek-R1-Distill-Qwen-7B 以及 Skywork-OR1-Math-7B [16]。每款模型均以温度 0.8、top-p 的 0.95 以及完整的 $B = 32{,}768$ token 预算生成其推演结果。

数据集 我们从多个基准来源收集问题，而不是单一来源，因为剪枝策略必须在部分问题上进行训练并在其余问题上进行评估，而没有任何一个竞赛基准足够大以同时满足这两者的需求。两个模型层级分别在不同的基准子集上进行评估，所选子集确保任一层级均未达到饱和。两个层级均使用 AIME 2024、2025 和 2026 以及 HMMT 2024、2025 和 2026 [2]，以及 RIMO-N [9]。小型层级额外加入 BeyondAIME [4]、OlymMATH（简单）[37] 和 Omni-MATH 第 7 和第 8 级 [14]，而大型层级则用 AMO-Bench [27]、OlymMATH（困难）以及 Omni-MATH 第 8 和第 9 级替代上述内容。这使得每个模型大约有 600 个问题。对于每个模型，我们随后移除其在 128 次试验中全部正确或全部错误解题的问题。

验证。 一次完整的滚动评估被视为正确，当其最终答案与问题的参考答案一致时。我们从滚动的 `\boxed{}` 表达式中获取该答案，并请 Qwen3-32B 判定器 [49] 判断其是否与参考答案等价。我们使用判别器而非符号检查工具（如 `math-verify` [24]），因为像 AMO-Bench 这类基准测试包含描述性答案，符号检查工具无法处理。

评估。 每个模型可用的问题仅有几百个，因此将问题划分为训练集和测试集的单一划分会导致两边数量都太少，故我们改用交叉验证进行评估。对于每个模型，我们将问题划分为八个折，使每个基准问题均匀分布于各折中。每折依次作为测试集，而学成的组件则在其余七折上进行训练，因此每个问题都会被一个未在其上训练过的模型恰好评分一次。完成所有八折的一次遍历构成一次重复。由于一次重复的结果取决于问题如何被划分，我们运行 20 次重复，每次均通过在分配问题到各折前对每个基准的问题进行随机打乱，获得新的随机划分，并使用全新的随机种子进行训练。所有报告的数据均为 20 次重复的平均值，其标准差也由此计算得出。对于 RepExp，我们将正则化项设为 $\tau = 1$。对于所有方法，部分展开的表示 h_i 为其隐状态的指数移动平均（EMA），衰减率为 10^{-3}。

4.2 实验评估与比较

Figure 3 报告了我们的主要情景，其中每种方法从问题的前缀中选择 $k \in \{1, 2, 4, 8, 16\}$ 个 $N = 128$ 个回溯路径，我们将截止阈值设为 $T = 4000$ token。对于每个模型，它展示了每种剪枝策略的 pass@k 减去随机策略（Pass@k ）的结果，汇总所有测试问题的数据。随机策略以均匀随机的方式保留 k 个回溯路径，这等价于不进行任何剪枝地采样 k 个回溯路径，因此是自然的参照点。绝对数值见 Table 1，按基准的细分结果见 Appendix D。

如Fig. 3所示，线性探测器在 $k = 1$ 时表现良好，但随着 k 增大，其表现逐渐趋近于随机，如同 Qwen 模型的情况，在某些情况下甚至在 k 较大时表现比随机还差。这可以归因于模型对一组预测为正确但实际上可能错误的回溯路径存在偏差，尤其是在分类器出错的情况下。换句话说，通过探测器进行排序会使得保留的回溯路径的分布更加集中于探测器认为正确的区域。这一现象与强化学习中的观察结果一致：使用 GRPO 训练的模型在小 k 时优于基础模型，但在大 k 时反而被其超越 [53]。例如，Fig. 4展示了某一问题（Qwen3-8B, AMO-Bench）的 128 个回溯路径在表示的第

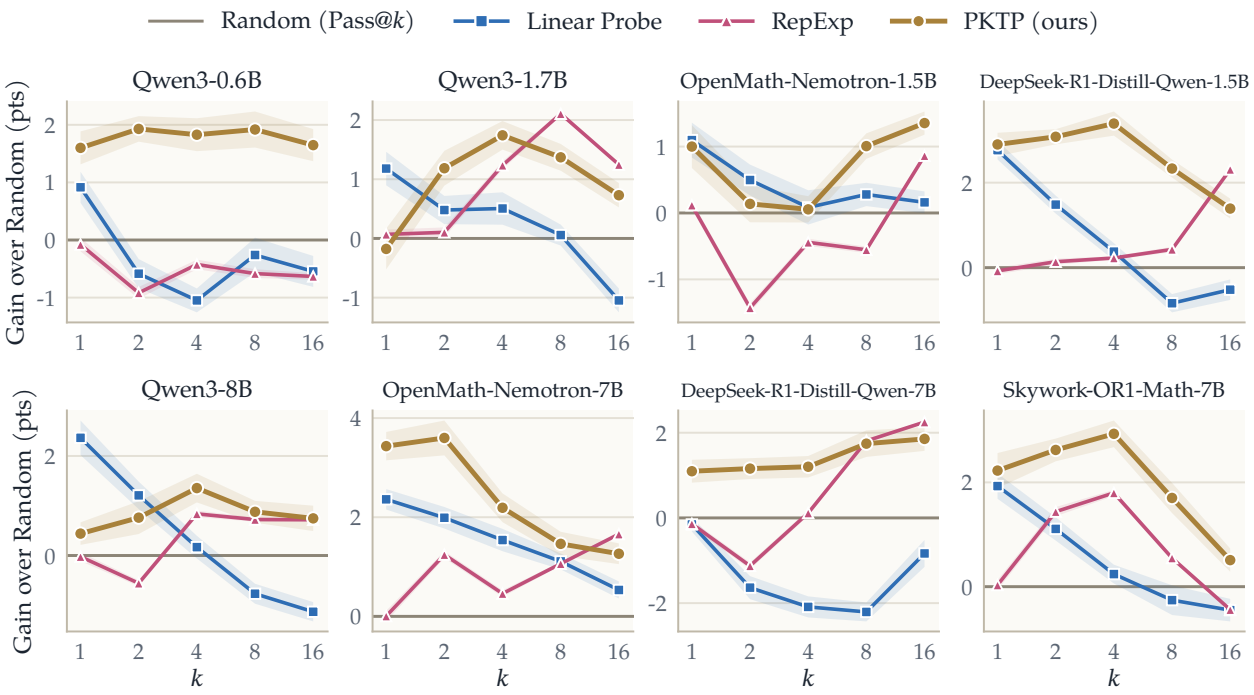


图 3: **剪枝策略相较于随机剪枝的性能提升**。对于每个模型，每种剪枝策略的联合 pass@k 减去随机剪枝（Pass@k）的值，以百分点为单位，作为保留轮次 k 的函数，并附带重复实验间差异的一倍标准差范围。绝对数值见 Table 1，各基准测试的分解结果见 Appendix D。

一二主成分上的投影。由探测器排名最高的 16 个回溯路径彼此接近且全部错误，而 16 个随机选取的回溯路径中则包含了 7 个正确的路径。

Figure 3 还表明，RepExp 的表现与线性探测（Linear Probe）恰好相反。在 $k = 1$ 时，如预期所示，其性能类似于随机选择（Random），因为其首次选择是随机的。随着 k 增大，总体趋势是 RepExp 逐渐优于随机选择，尤其是在 $k = 16$ 时表现尤为明显（例如，DeepSeek-R1-Distill 模型）。然而，有趣的是，在中等 k 情况下，有时 RepExp 反而被随机选择超越，例如在 OpenMath-Nemotron-1.5B 和 Qwen3-8B 上。我们将其归因于 RepExp 在小和中等 k 时倾向于选择异常值，因为距离已选样本最远的采样序列往往是不寻常的，不太可能正确。类似的现象也出现在 Tuyls et al. [39] 中，当温度较高时，RepExp 的帮助作用减弱，因为此时响应的连贯性较差，在表示空间中看起来新颖，但并不一定包含正确答案。例如，Fig. 5 展示了某一问题（Qwen3-8B，Omni-MATH）的 128 个采样结果，通过多维缩放（multidimensional scaling）将其表示嵌入二维空间。在首次随机选择之后，RepExp 选择了远离其他采样结果的异常值，且其所有 4 次选择均错误，而 4 次随机选择中却包含了 1 个正确的结果。

最后，Fig. 3 表明 PKTP 在性能上优于线性探针（Linear Probe）和 RepExp，且其优势在中等 k 下最为显著，此时各基准方法均受到自身偏差的影响。例如，在 DeepSeek-R1-Distill-Qwen-1.5B 模型上、$k = 4$ 条件下，PKTP 分别比线性探针高 3.0 分，比 RepExp 高 3.2 分；在 Qwen3-0.6B 模

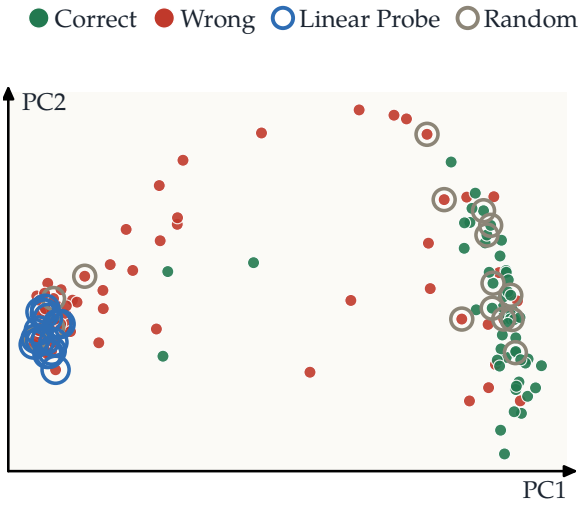


图 4: **线性探测保留了一组共同失败的回溯**。在一个问题（Qwen3-8B，AMO-Bench）中，将 128 回溯投影到其表示的第一二主成分上，正确回溯用绿色表示，错误回溯用红色表示。由线性探测排名最高的 16 回溯（蓝色环）彼此靠近且全部错误，而 16 随机选择的回溯（灰色环）则包含了 7 正确的回溯。

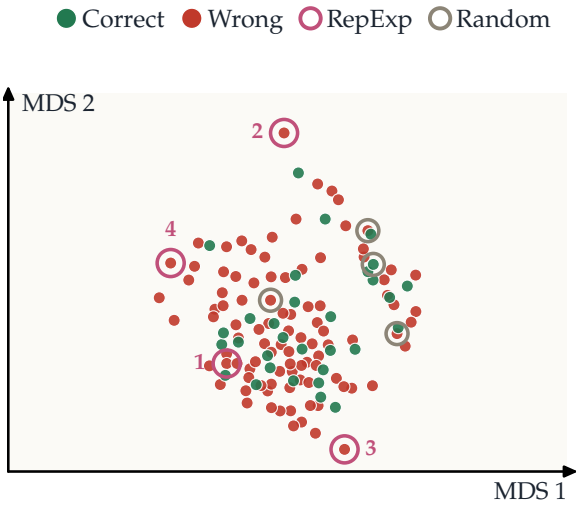


图 5: **RepExp 保留了不太可能正确的异常值**。对于一个问题（Qwen3-8B，Omni-MATH）的 128 次推演，通过其表示的多维缩放嵌入到二维空间中，正确推演用绿色表示，错误推演用红色表示。在随机首次选择后，RepExp（粉红色环，按选择顺序编号）选择了与其他推演相距较远的推演，且其 4 次选择全部错误，而 4 次随机选择（灰色环）中包含了 1 个正确推演。

型上，PKTP 在所有 $k \geq 2$ 下均领先两个基准方法超过 2 分；而在 DeepSeek-R1-Distill-Qwen-7B 模型上，PKTP 在 $k = 4$ 条件下比线性探针高出 3.3 分。与两个基准方法不同，PKTP 在所有模型上对 $k \geq 2$ 均保持高于随机基线（Random）的性能，这是因为 PKTP 在保留探针正确性信号的同时，将所保留的推演（rollouts）分散至彼此间不太可能同时失败的结果上。然而，在较大

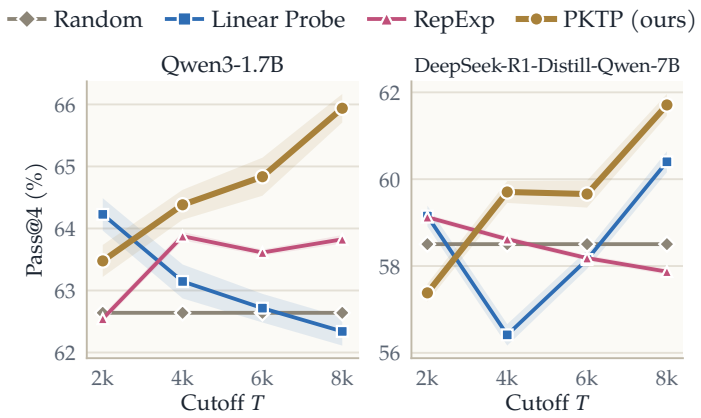


图 6: **较晚的截断有助于提升 PKTP**。在 Qwen3-1.7B 和 DeepSeek-R1-Distill-Qwen-7B 上，随着截断点 T 从 2000 增加到 8000 token，Pass@4 也随之提高，其中 $N = 128$ 。对于每个 $T \geq 4000$ ，PKTP 表现最佳，并且随着前缀长度增加持续改进；而线性探测和 RepExp 的提升幅度小得多，且在 Qwen3-1.7B 上的线性探测甚至低于随机水平。误差带为一个标准差。

的 k 下，PKTP 与 RepExp 的性能趋于接近。我们认为这是由于部分推演（partial rollouts）嵌入（embedding）中的正确性信号较弱所致，这引出了一个关键问题：如何从部分推演中获得高质量的嵌入，以及这是否在原则上可行。

其他池大小 $N \in \{32, 48, 64, 80, 96, 112\}$ 在相同截断值 $T = 4000$ 下的结果见 Appendix E。

4.3 截止阈值的影响

剪枝的一个重要方面是截断阈值 T，以及算法随阈值增大时的行为表现。Figure 6 在 Qwen3-1.7B 和 DeepSeek-R1-Distill-Qwen-7B 上对 T 进行了变化。对于每一个 $T \geq 4000$，PKTP 在两个模型上的表现均优于其他所有方法。一个有趣的观察是，通常情况下，较晚的截断阈值会提升 PKTP 的性能。在 Qwen3-1.7B 上，其 pass@4 从 63.5%（在 $T = 2000$ 时）上升至 65.9%（在 $T = 8000$ 时），在 DeepSeek-R1-Distill-Qwen-7B 上则从 57.4% 上升至 61.7%。直观上，生成的 token 越多，关于一次回放的质量及其发展方向的信息就越多，因此可利用的信号也越丰富。然而，有趣的是，线性探测（Linear Probe）和 RepExp 并不必然呈现相同趋势。例如，在 Qwen3-1.7B 上，线性探测的表现从 64.2% 下降至 62.3%，最终低于随机基线。其中一个原因可能是我们所采用的表示方式。由于带有速率 10^{-3} 的指数移动平均（EMA）实际上对最近的 1000 个 token 进行了平均，可能会丢失早期 token 中的信号。

4.4 池大小的影响

剪枝的另一个重要方面是所选 N 池的大小，即从中选取 k rollout 的池。在 Qwen3-1.7B 与 DeepSeek-R1-Distill-Qwen-7B 上，Figure 7 随 N 变化。PKTP 在 Qwen3-1.7B 的所有 N 上均优于其他所有方法；而在 DeepSeek-R1-Distill-Qwen-7B 上，一旦池大小达到 $N = 80$ ，PKTP 亦表

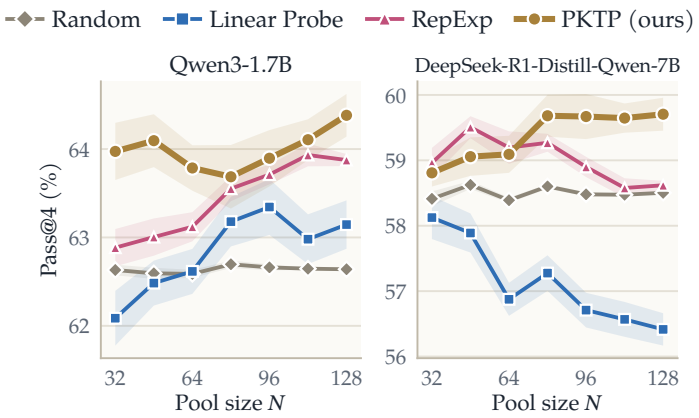


图 7: **当池的大小足够大时，PKTP 的表现领先**。在 Qwen3-1.7B 和 DeepSeek-R1-Distill-Qwen-7B 上，随着池大小 N 从 32 增加到 128，Pass@4 也随之变化，其中 $T = 4000$。在 Qwen3-1.7B 上，对于每个 N，PKTP 是最佳方法；在 DeepSeek-R1-Distill-Qwen-7B 上，从 $N = 80$ 开始，线性探测（Linear Probe）的表现随池增大而下降，并始终低于随机选择。阴影区域为一个标准差。

现更优。更大的池提供了更多候选对象可供选择；在 Qwen3-1.7B 上，两种基准方法均由此获益：RepExp 随池多样性提升，从 62.9% （对应 $N = 32$ ）上升至 63.9% （对应 $N = 128$ ），而线性探针（Linear Probe）则从 62.1% 提升至 63.1% 。然而有趣的是，在 DeepSeek-R1-Distill-Qwen-7B 上却并非如此：线性探针性能从 58.1% 下降至 56.4% ，且在所有 N 下均低于随机方法；RepExp 亦从 59.5% （对应 $N = 48$ ）下降至 58.6% ；而 PKTP 则从 58.8% 上升至 59.7% 。一个可能的原因是，更大的池中也包含更多异常值，从而提高了 RepExp 与线性探针等方法在中等 k （例如 $k = 4$ ）下选中极端案例的概率。

5 结论

我们提出了 PKTP，这是一种剪枝框架，通过直接优化 pass@k 来决定保留哪些部分回溯。PKTP 使用潜在高斯模型学习回溯结果的联合分布，以闭式近似得到的似然，并贪婪地选择保留集合，且对代理目标具有近似保证。在八种推理模型中，它均优于基于质量与基于多样性的剪枝方法，且在中等 k 水平下增益最大，此时这些基准方法均因自身偏差而表现不佳。由于 PKTP 可与任意部分回溯表示结合，若能开发出更准确捕捉回溯正确性的表示，将直接增强其性能，这将成为未来工作的一个自然方向。

致谢

本工作部分得到南加州大学研究与创新办公室颁发的生成式人工智能研究奖、美国国家科学基金会训练计划（NSF NRT）、南加州大学-元公司人工智能与学习研究中心以及亚马逊公司的捐赠支持。AJ 的部分工作得到美国国家科学基金会资助项目 DMS-2311024、亚马逊教师研究奖、Adobe

教师研究奖以及南加州大学马歇尔商学院 iORB 基金的支持。

人工智能使用声明

在本工作中，我们使用生成式 AI 工具协助完成了项目的多个部分。对于文稿撰写，我们使用它们来编辑和润色文本，并格式化 LaTeX 源代码。对于图表，我们使用它们来编写绘制实验结果的脚本。对于代码，我们使用它们来帮助实现部分代码。对于理论部分，我们使用它们来帮助推导并撰写附录中的部分证明。我们并未使用生成式 AI 工具生成数据或实验结果。所有由 AI 辅助的内容，包括代码和证明，均经过作者的审查与验证，作者对本文内容负全部责任。

参考文献

[1] Anum Afzal, Florian Matthes, Gal Chechik, and Yftah Ziser. Knowing before saying: LLM representations encode information about chain-of-thought success before completion. In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 12791–12806, 2025.

[2] Mislav Balunović, Jasper Dekoninck, Ivo Petrov, Nikola Jovanović, and Martin Vechev. MathArena: Evaluating LLMs on uncontaminated math competitions. In *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*, 2025.

[3] Bradley Brown, Jordan Juravsky, Ryan Ehrlich, Ronald Clark, Quoc V Le, Christopher Ré, and Azalia Mirhoseini. Large language monkeys: Scaling inference compute with repeated sampling. *arXiv preprint arXiv:2407.21787*, 2024.

[4] ByteDance Seed. Seed1.5-Thinking: Advancing superb reasoning models with reinforcement learning. *arXiv preprint arXiv:2504.13914*, 2025.

[5] Jaime Carbonell and Jade Goldstein. The use of MMR, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 1998.

[6] Harr Chen and David R. Karger. Less is more: Probabilistic models for retrieving fewer relevant documents. In *Proceedings of the 29th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 429–436, 2006.

[7] Yilei Chen, Souradip Chakraborty, Lorenz Wolf, Yannis Paschalidis, and Aldo Pacchiano. Post-training large language models for diverse high-quality responses. In *International Conference on Learning Representations*, 2026.

[8] Zhipeng Chen, Xiaobo Qin, Youbin Wu, Yue Ling, Qinghao Ye, Wayne Xin Zhao, and Guang Shi. Pass@k training for adaptively balancing exploration and exploitation of large reasoning models. *arXiv preprint arXiv:2508.10751*, 2025.

[9] Ziye Chen, Chengwei Qin, and Yao Shu. RIMO: An easy-to-evaluate, hard-to-solve olympiad benchmark for advanced mathematical reasoning. *arXiv preprint arXiv:2509.07711*, 2025.

[10] Yinlam Chow, Guy Tennenholtz, Izzeddin Gur, Vincent Zhuang, Bo Dai, Sridhar Thiagarajan, Craig Boutilier, Rishabh Agarwal, Aviral Kumar, and Aleksandra Faust. Inference-aware fine-tuning for best-of-N sampling in large language models. In *International Conference on Learning Representations*, 2025.

[11] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse,

and John Schulman. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.

[12] Rick Durrett. *Probability: Theory and Examples*. Cambridge University Press, 5th edition, 2019. doi: 10.1017/9781108591034.

[13] Yichao Fu, Xuewei Wang, Hao Zhang, Yuandong Tian, and Jiawei Zhao. Deep think with confidence. In *International Conference on Learning Representations*, 2026.

[14] Bofei Gao, Feifan Song, Zhe Yang, Zefan Cai, Yibo Miao, Qingxiu Dong, Lei Li, Chenghao Ma, Liang Chen, Runxin Xu, et al. Omni-MATH: A universal olympiad level mathematic benchmark for large language models. In *International Conference on Learning Representations*, 2025.

[15] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, Runxin Xu, Ruoyu Zhang, Shirong Ma, Xiao Bi, et al. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*, 645(8081):633–638, 2025.

[16] Jujie He, Jiacai Liu, Chris Yuhao Liu, Rui Yan, Chaojie Wang, Peng Cheng, Xiaoyu Zhang, Fuxiang Zhang, Jiacheng Xu, Wei Shen, et al. Skywork open reasoner 1 technical report. *arXiv preprint arXiv:2505.22312*, 2025.

[17] Parsa Hosseini, Sumit Nawathe, Mahdi Salmani, Meisam Razaviyayn, and Soheil Feizi. Early stopping for large reasoning models via confidence dynamics. *arXiv preprint arXiv:2604.04930*, 2026.

[18] Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. OpenAI o1 system card. *arXiv preprint arXiv:2412.16720*, 2024.

[19] Xinyan Jiang, Ninghao Liu, Di Wang, and Lijie Hu. Beyond scalars: Evaluating and understanding LLM reasoning via geometric progress and stability. In *International Conference on Machine Learning*, 2026.

[20] Richard M. Karp. Reducibility among combinatorial problems. In *Complexity of Computer Computations*, pages 85–103. Plenum Press, 1972.

[21] Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. Large language models are zero-shot reasoners. *Advances in Neural Information Processing Systems*, 35:22199–22213, 2022.

[22] Alex Kulesza and Ben Taskar. Determinantal point processes for machine learning. *Foundations and Trends in Machine Learning*, 5(2–3):123–286, 2012.

[23] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th Symposium on Operating Systems Principles*, pages 611–626, 2023.

[24] Hynek Kydlíček. Math-Verify: Math verification library. `https://github.com/huggingface/Math-Verify`, 2025.

[25] Zhixiang Liang, Beichen Huang, Zheng Wang, and Minjia Zhang. Hidden states as early signals: Step-level trace evaluation and pruning for efficient test-time scaling. In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 26800–26813, 2026.

[26] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step. In *International Conference on Learning Representations*, 2024.

[27] Junlin Liu, Shengnan An, Shuang Zhou, Dan Ma, Yehao Lin, Xinxuan Lv, Xuanlin Wang, Xiaoyu Li, Ziwen Wang, Xuezhi Cao, and Xunliang Cai. AMO-Bench: Large language models still struggle in high school math competitions. In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 2120–2137, 2026.

[28] Xin Liu and Lu Wang. Answer convergence as a signal for early stopping in reasoning. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 17896–17907, 2025.

[29] Haolang Lu, Minghui Pan, Ripeng Li, Guoshun Nan, Jialin Zhuang, Zijie Zhao, Zhongxiang Sun, Kun Wang, and Yang Liu. Streaming hallucination detection in long chain-of-thought reasoning. In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 21157–21183, 2026.

[30] Rohin Manvi, Anikait Singh, and Stefano Ermon. Adaptive inference-time compute: LLMs can predict if they can do better, even mid-generation. *arXiv preprint arXiv:2410.02725*, 2024.

[31] Ivan Moshkov, Darragh Hanley, Ivan Sorokin, Shubham Toshniwal, Christof Henkel, Benedikt Schifferer, Wei Du, and Igor Gitman. AIMO-2 winning solution: Building state-of-the-art mathematical reasoning models with OpenMathReasoning dataset. *arXiv preprint arXiv:2504.16891*, 2025.

[32] George L. Nemhauser, Laurence A. Wolsey, and Marshall L. Fisher. An analysis of approximations for maximizing submodular set functions. *Mathematical Programming*, 14(1):265–294, 1978.

[33] Reiner Pope, Sholto Douglas, Aakanksha Chowdhery, Jacob Devlin, James Bradbury, Jonathan Heek, Kefan Xiao, Shivani Agrawal, and Jeff Dean. Efficiently scaling transformer inference. *Proceedings of Machine Learning and Systems*, 5:606–624, 2023.

[34] Scott Sanner, Shengbo Guo, Thore Graepel, Sadegh Kharazmi, and Sarvnaz Karimi. Diverse retrieval via greedy optimization of expected 1-call@k in a latent subtopic relevance model. In *Proceedings of the 20th ACM International Conference on Information and Knowledge Management*, 2011.

[35] Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling LLM test-time compute optimally can be more effective than scaling parameters for reasoning. In *International Conference on Learning Representations*, 2025.

[36] Hanshi Sun, Momin Haider, Ruiqi Zhang, Huitao Yang, Jiahao Qiu, Ming Yin, Mengdi Wang, Peter Bartlett, and Andrea Zanette. Fast best-of-N decoding via speculative rejection. In *Advances in Neural Information Processing Systems*, 2024.

[37] Haoxiang Sun, Yingqian Min, Zhipeng Chen, Wayne Xin Zhao, and Ji-Rong Wen. Challenging the boundaries of reasoning: An olympiad-level math benchmark for large language models. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 17438–17457, 2026.

[38] Lihao Sun, Hang Dong, Bo Qiao, Qingwei Lin, Dongmei Zhang, and Saravan Rajmohan. LLM reasoning as trajectories: Step-specific representation geometry and correctness signals. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 26872–26887, 2026.

[39] Jens Tuyls, Dylan J. Foster, Akshay Krishnamurthy, and Jordan T. Ash. Representation-based exploration for language models: From test-time to post-training. In *International Conference on Learning Representations*, 2026.

[40] Martina G. Vilas, Safoora Yousefi, Besmira Nushi, Eric Horvitz, and Vidhisha Balachandran. Tracing the traces: Latent temporal signals for efficient and accurate reasoning. In *International Conference on Learning Representations*, 2026.

[41] Christian Walder and Deep Tejas Karkhanis. Pass@K policy optimization: Solving harder reinforcement learning problems. In *Advances in Neural Information Processing Systems*, volume 38, pages 152416–152445, 2025.

[42] Sophie L. Wang, Phillip Isola, and Brian Cheung. The truth lies somewhere in the middle (of the generated tokens). In *International Conference on Machine Learning*, 2026.

[43] Xi Wang, James McInerney, Lequn Wang, and Nathan Kallus. Entropy after `</think>` for reasoning model early exiting. *arXiv preprint arXiv:2509.26522*, 2025.

[44] Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. In *International Conference on Learning Representations*, 2023.

[45] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35:24824–24837, 2022.

[46] James T. Wilson, Frank Hutter, and Marc Peter Deisenroth. Maximizing acquisition functions for Bayesian optimization. In *Advances in Neural Information Processing Systems*, 2018.

[47] Xueqing Wu, Langxing Bai, Hritik Bansal, Po-Nien Kung, Shuo Li, Hao Liu, Nanyun Peng, and Kai-Wei Chang. Planned test-time scaling with coordinated reasoning paths. *arXiv preprint arXiv:2609.27374*, 2026.

[48] Yangzhen Wu, Zhiqing Sun, Shanda Li, Sean Welleck, and Yiming Yang. Inference scaling laws: An empirical analysis of compute-optimal inference for LLM problem-solving. In *International Conference on Learning Representations*, 2025.

[49] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

[50] Chenxu Yang, Qingyi Si, Yongjie Duan, Zheliang Zhu, Chenyu Zhu, Qiaowei Li, Minghui Chen, Zheng Lin, and Weiping Wang. Dynamic early exit in reasoning models. In *International Conference on Learning Representations*, volume 2026, pages 88170–88210, 2026.

[51] Lijie Yang, Hongyin Luo, Jiawei Zhao, Tri Dao, and Ravi Netravali. Thought-level beam search for reasoning. In *Conference on Language Modeling*, 2026.

[52] Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Tom Griffiths, Yuan Cao, and Karthik Narasimhan. Tree of thoughts: Deliberate problem solving with large language models. *Advances in Neural Information Processing Systems*, 36:11809–11822, 2023.

[53] Yang Yue, Zhiqi Chen, Rui Lu, Andrew Zhao, Zhaokai Wang, Yang Yue, Shiji Song, and Gao Huang. Does reinforcement learning really incentivize reasoning capacity in LLMs beyond the base model? In *Advances in Neural Information Processing Systems*, 2025.

[54] Anqi Zhang, Yulin Chen, Jane Pan, Chen Zhao, Aurojit Panda, Jinyang Li, and He He. Reasoning models know when they're right: Probing hidden states for self-verification. In *Conference on Language Modeling*, 2025.

A 推导

A.1 似然

写 $\mathbf{Z}_i = q_i + \mathbf{m}_i + h_i^\top \mathbf{f}$ 。在 $\mathbf{f}$ 的条件下，$\mathbf{Z}_i$ 相互独立，因此

$$\Pr\left[\mathbf{C}_1 = c_1, \ldots, \mathbf{C}_N = c_N \mid \mathbf{f}\right] = \prod_{i=1}^{N} \Pr[c_i \mathbf{Z}_i \geq 0 \mid \mathbf{f}] \tag{15}$$

$$= \prod_{i=1}^{N} \Pr[c_i(q_i + \mathbf{m}_i + h_i^\top \mathbf{f}) \geq 0 \mid \mathbf{f}] \tag{16}$$

$$= \prod_{i=1}^{N} \Pr[c_i \mathbf{m}_i \geq -c_i(q_i + h_i^\top \mathbf{f}) \mid \mathbf{f}]. \tag{17}$$

由于标准高斯分布关于 0 对称，$-c_i\mathbf{m}_i$ 与 $\mathbf{m}_i$ 同分布，且当 $\Phi(x) := \Pr_{Z\sim\mathcal{N}(0,1)}[Z \leq x]$ 时每个因子等于 $\Phi\big(c_i(q_i + h_i^\top \mathbf{f})\big)$。对两边关于 $\mathbf{f}$ 取期望，得到 Eq. 5。

A.2 秩一贪婪更新

如Corollary 1所示，设 $\Sigma_S = \sum_{i\in S} \kappa_i h_i h_i^\top$ 和 $b_S = \sum_{i\in S} \lambda_i h_i$。写出 $\Omega_S = (I_d + \Sigma_S)^{-1}$、$r_j = h_j^\top \Omega_S h_j$ 和 $u_j = h_j^\top \Omega_S b_S$。增加一个候选 $j \notin S$ 会使 Σ_S 改变一个秩一矩阵 $\kappa_j h_j h_j^\top$。矩阵行列式引理给出

$$\det(I_d + \Sigma_S + \kappa_j h_j h_j^\top) = \det(I_d + \Sigma_S)\big(1 + \kappa_j r_j\big), \tag{18}$$

而 Sherman-Morrison 公式给出

$$(I_d + \Sigma_S + \kappa_j h_j h_j^\top)^{-1} = \Omega_S - \frac{\kappa_j \Omega_S h_j h_j^\top \Omega_S}{1 + \kappa_j r_j}. \tag{19}$$

将 Eq. 18 和 Eq. 19 代入 Eq. 11，并利用 $b_{S\cup\{j\}} = b_S + \lambda_j h_j$，对应的未折半二次型的变化为

$$2\lambda_j u_j + \lambda_j^2 r_j - \frac{\kappa_j (u_j + \lambda_j r_j)^2}{1 + \kappa_j r_j} = \frac{2\lambda_j u_j + \lambda_j^2 r_j - \kappa_j u_j^2}{1 + \kappa_j r_j}. \tag{20}$$

该式的一半，加上行列式项中的变化 $-\frac{1}{2}\log(1 + \kappa_j r_j)$ 以及新的品质项 $\log \Phi(-q_j)$ ，得到

$$\Delta_j(S) = \log \widetilde{L}(S \cup \{j\}) - \log \widetilde{L}(S) = \log \Phi(-q_j) - \frac{1}{2}\log(1 + \kappa_j r_j) + \frac{2\lambda_j u_j + \lambda_j^2 r_j - \kappa_j u_j^2}{2(1 + \kappa_j r_j)}. \tag{21}$$

贪心步骤添加具有最小 $\Delta_j(S)$ 的候选者。在选择 j 后，所维护的 State 更新为

$$\Omega_{S\cup\{j\}} = \Omega_S - \frac{\kappa_j \Omega_S h_j h_j^\top \Omega_S}{1 + \kappa_j r_j}, \qquad b_{S\cup\{j\}} = b_S + \lambda_j h_j. \tag{22}$$

剩余的标量 r_ℓ 和 u_ℓ 也可以递归地进行更新。如果 $g_\ell = h_\ell^\top \Omega_S h_j$ ，则

$$r_\ell \leftarrow r_\ell - \frac{\kappa_j g_\ell^2}{1 + \kappa_j r_j}, \qquad u_\ell \leftarrow u_\ell + \frac{\lambda_j - \kappa_j u_j}{1 + \kappa_j r_j}\, g_\ell. \tag{23}$$

在保留所有 h_i 于内存中的情况下，每个贪心步骤的开销为 $O(Nd + d^2)$ ，因此一次前向传播需要 $O\big(k(Nd + d^2)\big)$ 时间和 $O(Nd + d^2)$ 存储空间。而一种朴素的实现方式是为每个候选重新构建并分解 $I_d + \Sigma_S + \kappa_j h_j h_j^\top$ ，其每个候选的开销为 $O(d^3)$ ，因此总时间为 $O(kNd^3)$ ，存储空间仍为 $O(Nd + d^2)$ 。

A.3 贪婪的边际在等质量极限下

假设每个质量得分都等于一个公共值 q，因此对每个 i 有 $\lambda_i = \lambda$ 且 $\kappa_i = \kappa$，同时忽略罚项，则 Eq. 11 简化为

$$\log \widetilde{L}(S) = |S| \log \Phi(-q) - \frac{1}{2} \log\det(I_d + \Sigma_S), \qquad \Sigma_S = \kappa \sum_{i \in S} h_i h_i^\top. \tag{24}$$

添加候选 $j \notin S$ 会通过一个秩为一的矩阵 $\kappa h_j h_j^\top$ 改变 Σ_S。矩阵行列式引理：对于可逆矩阵 A，有 $\det(A + uv^\top) = \det(A)\big(1 + v^\top A^{-1} u\big)$，将 $A = I_d + \Sigma_S$ 和 $u = v = \sqrt{\kappa}\, h_j$ 代入可得

$$\det(I_d + \Sigma_{S \cup \{j\}}) = \det(I_d + \Sigma_S)\big(1 + \kappa\, h_j^\top (I_d + \Sigma_S)^{-1} h_j\big). \tag{25}$$

从 Eq. 24 at $S \cup \{j\}$ 中减去 Eq. 24 at S ，并使用 Eq. 25，因子 $\det(I_d + \Sigma_S)$ 被消去

$$\Delta_j(S) = \log \Phi(-q) - \frac{1}{2}\Big(\log\det(I_d + \Sigma_{S \cup \{j\}}) - \log\det(I_d + \Sigma_S)\Big) \tag{26}$$

$$= \log \Phi(-q) - \frac{1}{2} \log\big(1 + \kappa\, h_j^\top (I_d + \Sigma_S)^{-1} h_j\big). \tag{27}$$

Eq. 27 的第一项对每个候选者都相同，且 $x \mapsto \log(1 + \kappa x)$ 随 $\kappa > 0$ 增大而增大，因此 $\Delta_j(S)$ 最小的候选者具有最大的 $h_j^\top (I_d + \Sigma_S)^{-1} h_j$。此外，$(I_d + \Sigma_S)^{-1} = \kappa^{-1}\big(\kappa^{-1} I_d + \sum_{i \in S} h_i h_i^\top\big)^{-1}$，因此该排序即为 Section 2 的 RepExp 规则，其正则化项为 $\tau = 1/\kappa$。

B 证明

B.1 Theorem 1 and Corollary 1 的证明

B.1.1 证明见 Theorem 1

此处 $\Pr[\mathbf{C} = c \mid H]$ 由 Eq. 5 给出。固定结果 $c \in \{-1, 1\}^N$ ，并写出 λ_i ， κ_i ， Σ 和 b 对应的 $\lambda_i(c_i)$ ， $\kappa_i(c_i)$ ， $\Sigma(c)$ 和 $b(c)$ 。对于每个 $i \in [N]$ 以及标量扰动 x ，令 $\ell_i(x) := \log \Phi\big(c_i(q_i + x)\big)$ ，并令 $r(u) := \phi(u)/\Phi(u)$ 满足 $r'(u) = -r(u)\big(u + r(u)\big)$ 。由于 $c_i^2 = 1$ 且 ϕ 为偶函数，有 $r(c_i q_i) = \lambda_i$ ，且

$$\ell_i'(x) = c_i\, r\big(c_i(q_i + x)\big) \implies \ell_i'(0) = c_i\lambda_i, \qquad \ell_i''(0) = r'(c_i q_i) = -\lambda_i(\lambda_i + c_i q_i) = -\kappa_i. \tag{28}$$

要看出 $\kappa_i > 0$ ，令 $u = c_i q_i$ 。对于 $u \geq 0$ ，这直接由 $\lambda_i > 0$ 得出。对于 $u < 0$ ，

$$\Phi(u) = \int_{|u|}^{\infty} \phi(t)\, dt < \frac{1}{|u|} \int_{|u|}^{\infty} t\phi(t)\, dt = \frac{\phi(u)}{|u|}, \tag{29}$$

因此 $\lambda_i > |u| = -c_i q_i$。在 $x = 0$ 附近的泰勒展开现在给出

$$\log \Phi\big(c_i(q_i + x)\big) = \log \Phi(c_i q_i) + c_i\lambda_i x - \frac{\kappa_i}{2}x^2 + R_i(x), \qquad R_i(x) = O(|x|^3). \tag{30}$$

我们现在代入 $x = h_i^\top \mathbf{f}$ 并对 Eq. 30 求和 $i \in [N]$。由于 $\mathbf{f}$ 对所有 $i \in [N]$ 都相同，所出现的仅有的总体量是 Σ 和 b，且期望内的项可写为

$$\prod_{i=1}^{N} \Phi\big(c_i(q_i + h_i^\top \mathbf{f})\big) = \left(\prod_{i=1}^{N} \Phi(c_i q_i)\right) \exp\left(b^\top \mathbf{f} - \frac{1}{2}\mathbf{f}^\top \Sigma \mathbf{f} + \sum_{i=1}^{N} R_i(h_i^\top \mathbf{f})\right). \tag{31}$$

舍弃累积余数得到二次近似

$$\widetilde{\Pr}[\mathbf{C} = c \mid H] := \left(\prod_{i=1}^{N} \Phi(c_i q_i)\right) \mathbb{E}_{\mathbf{f}} \exp\left(b^\top \mathbf{f} - \frac{1}{2}\mathbf{f}^\top \Sigma \mathbf{f}\right). \tag{32}$$

公式Eq. 32中的期望具有闭式解。将其指数部分与标准高斯密度结合，得到

$$\mathbb{E}_{\mathbf{f}} \exp\left(b^\top \mathbf{f} - \frac{1}{2}\mathbf{f}^\top \Sigma \mathbf{f}\right) = (2\pi)^{-d/2} \int_{\mathbb{R}^d} \exp\left(-\frac{1}{2} f^\top (I_d + \Sigma) f + b^\top f\right) df. \tag{33}$$

由于 $\kappa_i > 0$、$\Sigma \succeq 0$ 以及矩阵 $I_d + \Sigma$ 是正定的。配方后，

$$-\frac{1}{2} f^\top (I_d + \Sigma) f + b^\top f = -\frac{1}{2}\big(f - (I_d + \Sigma)^{-1} b\big)^\top (I_d + \Sigma)\big(f - (I_d + \Sigma)^{-1} b\big) \tag{34}$$

$$+ \frac{1}{2} b^\top (I_d + \Sigma)^{-1} b. \tag{35}$$

将积分变量变换后，剩余的高斯积分贡献了 $\det(I_d + \Sigma)^{-1/2}$，从而得到 Eq. 9。 □

B.1.2 Corollary 1 的证明

将 S 以外的回溯结果积分掉后，得到与 Eq. 5 中乘积 $i \in S$ 相同的表达式，因此 Theorem 1 适用于 S 中的回溯，其中 $\Sigma_S(c)$ 和 $b_S(c)$ 分别是 $i \in S$ 的求和。对每个 $i \in S$ 取 $c_i = -1$ 。然后 $\lambda_i(-1) = \phi(q_i)/\Phi(-q_i)$ 、$\kappa_i(-1) = \lambda_i(\lambda_i - q_i)$ 和 $b_S(c) = -\sum_{i\in S} \lambda_i h_i$ ，在附录中我们记为 $b_S = \sum_{i\in S} \lambda_i h_i$ 。由于 b_S 仅通过 $b_S^\top (I_d + \Sigma_S)^{-1} b_S$ 出现在 Eq. 9 中，因此 $L(S)$ 的代理为 $\widetilde{L}(S)$ ，又因为对数函数是递增的，最小化 $\widetilde{L}(S)$ 等价于最小化 $\log \widetilde{L}(S)$ 。 □

B.2 证明 Theorem 2

确切的通过概率的次模性是事件并集概率的一个标准性质 [46]，我们在此为完整性起见给出其证明。新结果是代理函数保持了这一性质。

Definition 1 (Submodular function)**.** 集合函数 $G : 2^{[N]} \to \mathbb{R}$ 是次模的，如果对于任意 $A \subseteq B \subseteq [N]$ 和任意 $j \notin B$，

$$G(A \cup \{j\}) - G(A) \geq G(B \cup \{j\}) - G(B). \tag{36}$$

Definition 2 (Monotone function)**.** 集合函数 $G : 2^{[N]} \to \mathbb{R}$ 是单调的，如果当 $A \subseteq B \subseteq [N]$ 时，有 $G(A) \leq G(B)$。

Definition 3 (Normalized function)**.** 一个集合函数 $G : 2^{[N]} \to \mathbb{R}$ 是规范化的，如果 $G(\varnothing) = 0$ 。

B.2.1 子模性：确切的 pass@k 概率

首先，我们证明确切的 pass@k 概率已经是一个规范化的单调次模集合函数。为了说明这一点，令 $\mathcal{C}_i$ 表示响应 i 正确的事件。确切的通过概率可表示为

$$P(S) := \Pr\left(\bigcup_{i\in S} \mathcal{C}_i\right). \tag{37}$$

对于任意 $A \subseteq B \subseteq [N]$ 和 $j \notin B$，添加响应 j 所带来的边际改善为

$$P(A \cup \{j\}) - P(A) = \Pr\left(\mathcal{C}_j \setminus \bigcup_{i\in A} \mathcal{C}_i\right), \tag{38}$$

$$P(B \cup \{j\}) - P(B) = \Pr\left(\mathcal{C}_j \setminus \bigcup_{i\in B} \mathcal{C}_i\right). \tag{39}$$

由于 $A \subseteq B$ ，

$$\left(\mathcal{C}_j \setminus \bigcup_{i\in B} \mathcal{C}_i\right) \subseteq \left(\mathcal{C}_j \setminus \bigcup_{i\in A} \mathcal{C}_i\right). \tag{40}$$

因此，取概率即得

$$P(A \cup \{j\}) - P(A) \geq P(B \cup \{j\}) - P(B), \tag{41}$$

这正是子模函数的性质。此外，当 $A \subseteq B$ 时，$P(\varnothing) = 0$ 且 $P(A) \leq P(B)$。因此，确切通过概率是规范化的、单调的且具有子模性。这一结论对正确性事件的任意联合分布均成立，无需依赖潜在变量模型或条件独立性。

B.2.2 近似通过概率的子模性

现在，我们证明在高斯潜在模型下的近似本身是一个单调的子模函数。需要注意的是，一个子模函数的每一个近似并不一定仍然是子模的。在继续之前，让我们先直观地理解一下，$\widetilde{L}(S)$ 确实代表某种概率的概念。在给定 $\mathbf{f}$ 的条件下，$\widetilde{L}(S)$ 中乘积的每一项可以表示为

$$g_i(\mathbf{f}) := \Phi(-q_i)\exp\left(-\lambda_i h_i^\top \mathbf{f} - \frac{\kappa_i}{2}(h_i^\top \mathbf{f})^2\right). \tag{42}$$

因此，

$$\widetilde{L}(S) = \mathbb{E}_{\mathbf{f}\sim\mathcal{N}(0,I_d)} \prod_{i\in S} g_i(\mathbf{f}). \tag{43}$$

因此，为了使 $\widetilde{L}(S)$ 成为在给定 $\mathbf{f}$ 条件下选择正确元素的某种失败概率的定义，只需证明 $g_i(\mathbf{f}) < 1$。为此，对于标量 q，记

$$\lambda(q) := \frac{\phi(q)}{\Phi(-q)}, \qquad \kappa(q) := \lambda(q)(\lambda(q) - q), \tag{44}$$

并且定义

$$\beta(q) := \Phi(-q)\exp\left(\frac{\lambda(q)^2}{2\kappa(q)}\right) = \Phi(-q)\exp\left(\frac{\lambda(q)}{2(\lambda(q) - q)}\right). \tag{45}$$

Lemma 1. 对于每个有限的 $q \in \mathbb{R}$，都有 $0 < \beta(q) < 1$。此外，$\beta(q)$ 关于 q 严格递减。

证明. 令 $\overline{\Phi}(q) := \Phi(-q) = 1 - \Phi(q)$ 并设

$$v(q) := \lambda(q) - q > 0, \qquad r(q) := \log\beta(q) = \log\overline{\Phi}(q) + \frac{\lambda(q)}{2v(q)}. \tag{46}$$

由于 $\overline{\Phi}'(q) = -\phi(q)$ ，我们有

$$\frac{d}{dq}\log\overline{\Phi}(q) = -\lambda(q). \tag{47}$$

此外，直接微分可得

$$\lambda'(q) = \lambda(q)(\lambda(q) - q) = \lambda(q)v(q), \qquad v'(q) = \lambda(q)v(q) - 1. \tag{48}$$

因此，

$$r'(q) = -\lambda(q) + \frac{\lambda'(q)v(q) - \lambda(q)v'(q)}{2v(q)^2} = \frac{\lambda(q)}{2v(q)^2}\left(1 - qv(q) - 2v(q)^2\right). \tag{49}$$

仍需证明括号内的表达式为负数。为此，令 $X \sim N(0,1)$ 。利用以下事实，$\mathbb{E}[X \mid X > q] = \lambda(q)$ ，以及 $\mathbb{E}[X^2 \mid X > q] = 1 + q\lambda(q)$ ，我们得到

$$\mathbb{E}\left[X - q \;\middle|\; X > q\right] = v(q), \qquad \mathbb{E}\left[(X-q)^2 \;\middle|\; X > q\right] = 1 - qv(q). \tag{50}$$

因此，只需证明

$$\frac{1}{2}\mathbb{E}\left[(X-q)^2 \;\middle|\; X > q\right] \le \left(\mathbb{E}\left[X - q \;\middle|\; X > q\right]\right)^2. \tag{51}$$

为了证明上述表达式，考虑

$$T(x) := \Pr(X - q > x | X > q) = \frac{\overline{\Phi}(q + x)}{\overline{\Phi}(q)}, \qquad x \geq 0. \tag{52}$$

Under the conditional law given $X > q$, the random variable $X - q$ is nonnegative. Hence, by the tail-integral formula for second moments [12, Lemma 2.2.13],

$$\frac{1}{2}\mathbb{E}\big[(X-q)^2 \mid X > q\big] = \mathbb{E}\left[\int_0^\infty t\, \mathbf{1}_{\{X-q>t\}}\, dt \,\middle|\, X > q\right] \tag{53}$$

$$= \int_0^\infty t\, \Pr(X - q > t \mid X > q)\, dt = \int_0^\infty tT(t)\, dt. \tag{54}$$

期望与积分的交换由 Tonelli 定理 [12, Theorem 1.7.2] 保证，因为被积函数是非负的。此外，将 $t = x + y$ 代入内层积分，再次通过 Tonelli 定理交换积分顺序，我们得到

$$\int_0^\infty \int_0^\infty T(x+y)\, dx\, dy = \int_0^\infty \int_y^\infty T(t)\, dt\, dy = \int_0^\infty \int_0^t T(t)\, dy\, dt = \int_0^\infty tT(t)\, dt. \tag{55}$$

这里的积分区域是 $\{(y,t) : 0 \leq y \leq t < \infty\}$ ，而 T 的非负性保证了交换的合理性。我们知道 λ 严格递增，因为 $\lambda'(q) = \kappa(q) > 0$ 。因此，对于 $x, y > 0$ ，

$$\frac{T(x+y)}{T(x)} = \exp\left(-\int_x^{x+y} \lambda(q+t)\, dt\right) < \exp\left(-\int_0^y \lambda(q+t)\, dt\right) = T(y), \tag{56}$$

因此 $T(x+y) < T(x)T(y)$。于是，我们得到

$$\frac{1}{2}\mathbb{E}\left[(X-q)^2 \;\middle|\; X > q\right] = \int_0^\infty tT(t)\, dt = \int_0^\infty \int_0^\infty T(x+y)\, dx\, dy \tag{57}$$

$$< \left(\int_0^\infty T(x)\, dx\right)^2 = \left(\mathbb{E}\left[X - q \;\middle|\; X > q\right]\right)^2. \tag{58}$$

将 Eq. 50 与 Eq. 58 结合得到

$$1 - qv(q) - 2v(q)^2 < 0. \tag{59}$$

通过 Eq. 49，$r'(q) < 0$。最后，当 $q \to -\infty$ 时，$\overline{\Phi}(q) \to 1$，$\lambda(q) \to 0$，以及 $\lambda(q)/(2v(q)) \to 0$。因此 $r(q) \to 0$。由于 r 是严格递减的，对每个有限的 q 都有 $r(q) < 0$。等价地，$0 < \beta(q) < 1$，且 β 是严格递减的。 □

因此，回到 $g_i(\mathbf{f})$ ，对标量 $x = h_i^\top \mathbf{f}$ 配方得到

$$g_i(\mathbf{f}) = \Phi(-q_i) \exp\left(-\frac{\kappa_i}{2}\left(x + \frac{\lambda_i}{\kappa_i}\right)^2 + \frac{\lambda_i^2}{2\kappa_i}\right) \leq \beta(q_i) < 1 \tag{60}$$

由引理 1。因此，对每个 $0 < g_i(\mathbf{f}) < 1$ 和每个 i 均有 $\mathbf{f}$。故可定义近似 pass@k 概率如下：

$$\widetilde{P}(S) := 1 - \widetilde{L}(S). \tag{61}$$

由 Eq. 43 直接可得 $\widetilde{L}$ 在集合包含关系下递减，因此 $\widetilde{P} = 1 - \widetilde{L}$ 是单调的。此外，$\widetilde{P}(\varnothing) = 1 - 1 = 0$，所以 $\widetilde{P}$ 是规范化的。

现在令 $A \subseteq B$ 和 $j \notin B$。通过添加 j 所获得的边际改进是

$$\widetilde{P}(A \cup \{j\}) - \widetilde{P}(A) = \widetilde{L}(A) - \widetilde{L}(A \cup \{j\}) = \mathbb{E}_{\mathbf{f}}\left[(1 - g_j(\mathbf{f})) \prod_{i \in A} g_i(\mathbf{f})\right]. \tag{62}$$

由于每个 $g_i(\mathbf{f})$ 都位于 $(0, 1)$ 内，

$$(1 - g_j(\mathbf{f})) \prod_{i \in A} g_i(\mathbf{f}) \geq (1 - g_j(\mathbf{f})) \prod_{i \in B} g_i(\mathbf{f}) \tag{63}$$

逐点在 $\mathbf{f}$ 中。取期望可证明 $\widetilde{P}$ 是次模的。

B.2.3 贪婪保证

由于 $\widetilde{P}$ 是规范化的、单调的且子模的 (Appendix B.2.2)，根据 Nemhauser et al. [32]，贪心解满足 Theorem 2 的保证。 □

B.3 证明见 Proposition 1

证明. 我们证明, 即使所有 q_i 都等于同一个整数且所有 h_i 的元素取值于 $\{0,1\}$, 该问题仍是 NP-难的。我们从独立集问题进行归约，该问题要求判断一个图是否包含 k 个成对不相邻的顶点，且是 NP-完全的 [20]。设 G 是在顶点集 $[N]$ 上、边集为 E 、邻接矩阵为 A 、最大度为 $\Delta \geq 1$ 的图（无边的情况是平凡的)。对于 $S \subseteq [N]$ ，令 A_S 为由 S 诱导的子图的邻接矩阵，$e(S)$ 为其边数。我们构造一个实例，其极小化解恰好是大小为 k 的独立集（当这样的集合存在时)。

令 $d = |E| + N\Delta$。向量 $\mathbb{R}^d$ 的前 $|E|$ 个坐标由 G 的边索引，其余坐标被划分为 N 个块，每个顶点对应一个块，每块包含 Δ 个坐标。对于每个顶点 i，令 $h_i \in \{0,1\}^d$ 在所有与 i 相关的边对应的坐标上取值为 1，并在其自身块中的 $\Delta - \deg(i)$ 个坐标上也取值为 1。两个不同的顶点仅在相邻时共享非零坐标，且此时恰好共享一个，因此 $\|h_i\|_2^2 = \Delta$ 与 $h_i^\top h_j = A_{ij}$ 对 $i \neq j$ 成立，且 $\{h_i\}_{i\in S}$ 的 Gram 矩阵为 $\Delta I_k + A_S$。我们进一步设定对所有 i，$q_i = q$，其中整数 $q \leq -1$ 在下方固定，使得 $\lambda_i = \lambda$ 且 $\kappa_i = \kappa$。于是 $\Sigma_S = \kappa \sum_{i\in S} h_i h_i^\top$ 且 $b_S = \lambda \sum_{i\in S} h_i$，而 Eq. 11 读作

$$\log \widetilde{L}(S) = k \log \Phi(-q) - \frac{1}{2} D(S) + R(S), \tag{64}$$

其中 $D(S) = \log\det(I_d + \Sigma_S)$ 和 $R(S) = \frac{1}{2} b_S^\top (I_d + \Sigma_S)^{-1} b_S \geq 0$。由于 $q \leq -1$，我们有 $\Phi(-q) \geq \frac{1}{2}$，因此 $\lambda \leq 2\phi(q) < \frac{1}{2}$ 和 $\lambda|q| \leq 2|q|\phi(q) \leq 2\phi(1) < \frac{1}{2}$，其中我们使用了 $t\phi(t)$ 在 $t \geq 1$ 时递减的性质。由此可得

$$\lambda|q| \leq \kappa = \lambda^2 + \lambda|q| < 1. \tag{65}$$

我们首先证明，D 在独立集上恰好取得最大值，并具有明确的裕量。根据 Sylvester 行列式恒等式以及 Gram 矩阵的形式，

$$D(S) = \log\det\big((1+\kappa\Delta) I_k + \kappa A_S\big) = k\log(1+\kappa\Delta) + \sum_{j=1}^{k} \log(1+x_j), \qquad x_j = \frac{\kappa\mu_j}{1+\kappa\Delta}, \tag{66}$$

其中 $\mu_1, \ldots, \mu_k$ 是 A_S 的特征值。它们满足 $\sum_j \mu_j = \operatorname{tr} A_S = 0$、$\sum_j \mu_j^2 = \operatorname{tr} A_S^2 = 2e(S)$ 和 $|\mu_j| \leq \Delta$，因此有 $\sum_j x_j = 0$ 和 $|x_j| < 1$。若 S 线性无关，则 $A_S = 0$ 且 $D(S) = k\log(1+\kappa\Delta)$；否则 $e(S) \geq 1$，且对 $|x| < 1$ 有不等式 $\log(1+x) \leq x - x^2/8$，再结合 Eq. 65，可得

$$D(S) \leq k\log(1+\kappa\Delta) - \frac{1}{8}\sum_{j=1}^{k} x_j^2 = k\log(1+\kappa\Delta) - \frac{\kappa^2 e(S)}{4(1+\kappa\Delta)^2} \leq k\log(1+\kappa\Delta) - \frac{\kappa^2}{4(1+\Delta)^2}. \tag{67}$$

接下来，我们对 S 上的罚项进行一致性的界限定。由于 $(I_d + \Sigma_S)^{-1} \preceq I_d$ 与 $\big\|\sum_{i\in S} h_i\big\|_2^2 = k\Delta + 2e(S) \leq k(\Delta + k)$ ，我们有 $0 \leq R(S) \leq \frac{1}{2}\|b_S\|_2^2 \leq \frac{1}{2}\lambda^2 k(\Delta + k)$ 。

现在假设 G 包含一个大小为 k 的独立集 S° ，令 S 是一个大小为 k 且满足 $e(S) \geq 1$ 的集合。将两个界与 Eq. 65 结合，

$$\log \widetilde{L}(S) - \log \widetilde{L}(S^\circ) \geq \frac{1}{2}\big(D(S^\circ) - D(S)\big) - R(S^\circ) \geq \frac{\kappa^2}{8(1+\Delta)^2} - \frac{\lambda^2}{2} k(\Delta + k) \tag{68}$$

$$\geq \lambda^2\Big(\frac{q^2}{8(1+\Delta)^2} - \frac{k(\Delta+k)}{2}\Big), \tag{69}$$

且当 $q = -2(1+\Delta)(\Delta+k)$ 时，右边为正。采用此选择后，只要 G 包含大小为 k 的集合，则 $\log \widetilde{L}$ 的每个极小化解都是独立集，因此 G 包含大小为 k 的独立集当且仅当 $\log \widetilde{L}$ 的极小化解是独立的。该实例由 N 个维度为 $d = |E| + N\Delta$ 的二元向量和一个多项式规模的整数 q 组成，因此可在多项式时间内构造完成，从而证明了该结论。 □

B.4 证明 Proposition 2

本节证明了Proposition 2，该式描述了在各次模拟之间的相关性较弱时的失败概率及其替代表达式。为了在保持质量得分不变的情况下减弱各次模拟间的相关性，我们用 $\rho\,\mathbf{f}$ 替换 $\mathbf{f}$（对于 $\rho > 0$），从而得到

$$\mathbf{Z}_i = q_i + \rho\, h_i^\top \mathbf{f} + \mathbf{m}_i, \qquad \operatorname{Cov}(\mathbf{Z}_i, \mathbf{Z}_j \mid H) = \rho^2 h_i^\top h_j \quad (i \neq j), \tag{70}$$

且 $\rho = 1$ 恢复了 Section 3.1 的模型。质量得分 $q_i = Q_\theta(h_i)$ 和表示 h_i 保持固定。由于仅有乘积 $\rho\, h_i$ 进入模型，这等价于在 q_i 固定的情况下，将表示缩放为 ρ，如 Appendix C 中假设 (A2) 所述。集合 S 的失败概率变为

$$L(S) = \mathbb{E}_{\mathbf{f}} \prod_{i \in S} \Phi\big(-q_i - \rho\, h_i^\top \mathbf{f}\big), \tag{71}$$

且其代理为 Eq. 11，其中每个 h_i 均被替换为 $\rho\, h_i$。

Proof of Proposition 2. 令 $\varepsilon_i = \rho\, h_i^\top \mathbf{f}$ 为 $i \in S$ ，使得 $\varepsilon_S \sim \mathcal{N}(0, K)$ 与 $K_{ij} = \rho^2 h_i^\top h_j$ 相关，且令 $u_i(x) = \log \Phi(-q_i - x)$ 。则 $u_i'(0) = -\lambda_i$ 且 $u_i''(0) = -\kappa_i$ ，并且 $\log \Phi$ 的所有二阶或更高阶导数在 $\mathbb{R}$ 上有界。根据泰勒定理，对于所有 $x \in \mathbb{R}$ ，

$$u_i(x) - u_i(0) = -\lambda_i x - \frac{1}{2}\kappa_i x^2 + \frac{1}{6} u_i'''(0)\, x^3 + r_i(x), \qquad |r_i(x)| \le C x^4, \tag{72}$$

其中 C 与 ρ 无关。令 $X = \sum_{i \in S} \big(u_i(\varepsilon_i) - u_i(0)\big)$ ，使得 $L(S) = \prod_{i \in S} \Phi(-q_i)\, \mathbb{E}\, e^X$ 。由于 $\Phi \le 1$ ，我们有 $e^X \le M_S := \prod_{i \in S} \Phi(-q_i)^{-1}$ ，且指数函数的泰勒定理给出 $\big|e^X - 1 - X - \frac{1}{2}X^2 - \frac{1}{6}X^3\big| \le \frac{M_S}{24} X^4$ 。此外，$|X| \le C'\big(\|\varepsilon_S\| + \|\varepsilon_S\|^2\big)$ 对于某个常数 C' 成立，因此 $\mathbb{E}X^4 = O(\rho^4)$ 且

$$\mathbb{E}\, e^X = 1 + \mathbb{E}X + \frac{1}{2}\mathbb{E}X^2 + \frac{1}{6}\mathbb{E}X^3 + O(\rho^4). \tag{73}$$

ε_S 的奇数矩消失，其四阶矩为 $O(\rho^4)$。因此

$$\mathbb{E}X = -\frac{1}{2}\sum_{i \in S} \kappa_i K_{ii} + O(\rho^4), \qquad \mathbb{E}X^2 = \sum_{i,j \in S} \lambda_i \lambda_j K_{ij} + O(\rho^4), \qquad \mathbb{E}X^3 = O(\rho^4). \tag{74}$$

使用 $a := -\frac{1}{2}\sum_{i \in S} \kappa_i K_{ii} + \frac{1}{2}\sum_{i,j \in S} \lambda_i \lambda_j K_{ij} = O(\rho^2)$ ，得到 $\mathbb{E}\, e^X = 1 + a + O(\rho^4)$ ，因此有 $\log \mathbb{E}\, e^X = a + O(\rho^4)$ 。将双重求和拆分为对角线部分和非对角线部分，并利用 $\lambda_i^2 - \kappa_i = \lambda_i q_i$ 可得

$$a = \frac{\rho^2}{2}\sum_{i \in S} \lambda_i q_i \|h_i\|^2 + \rho^2 \sum_{i < j \in S} \lambda_i \lambda_j\, h_i^\top h_j, \tag{75}$$

这证明了 $\log L(S)$ 的展开式。

对于代理函数，将 Eq. 11 中的 $\rho\, h_i$ 替换为 h_i 后读作

$$\log \widetilde{L}(S) = \sum_{i \in S} \log \Phi(-q_i) - \frac{1}{2}\log\det(I_d + \rho^2 \Sigma_S) + \frac{\rho^2}{2}\, b_S^\top (I_d + \rho^2 \Sigma_S)^{-1} b_S. \tag{76}$$

由于 $\log\det(I_d + \rho^2\Sigma_S) = \rho^2 \operatorname{tr}\Sigma_S + O(\rho^4)$ 和 $(I_d + \rho^2\Sigma_S)^{-1} = I_d + O(\rho^2)$ ，

$$\log \widetilde{L}(S) = \sum_{i \in S} \log \Phi(-q_i) - \frac{\rho^2}{2}\sum_{i \in S} \kappa_i \|h_i\|^2 + \frac{\rho^2}{2}\Big\|\sum_{i \in S} \lambda_i h_i\Big\|^2 + O(\rho^4), \tag{77}$$

展开平方后，得到的展开式与 $\log L(S)$ 相同。 □

C 预算范围内的选择行为

Proposition 2 为当 k 增大时，PKTP 如何从线性探测（Linear Probe）过渡到表示扩展（RepExp）提供了直观理解，尤其是在相关系数较弱的情况下。本节针对固定的相关系数尺度 ρ，精确刻画了这一行为的两个极端情况。PKTP 从空集开始，反复添加具有最小 $\log \widetilde{L}(S \cup \{j\}) - \log \widetilde{L}(S)$ 的候选 j，我们称此为 *代理贪心规则*。在一端，*探测风格规则*保留 k 个具有最大 q_i 的候选，如同线性探测（Linear Probe）一般。在另一端，表示扩展（RepExp）本身也是一种隐式的贪心规则。在随机选择首个候选后，带有正则化项 τ 的 RepExp 在每一步都添加能最大程度提升 $\log\det(I_d + \tau^{-1} G_S)$ 的候选，其中 $G_S := \sum_{i \in S} h_i h_i^\top$ 是所保留表示的 Gram 矩阵（Appendix A.3）。

我们保留 Corollary 1 的记号，使用 $\lambda(q) := \phi(q)/\Phi(-q)$、$\kappa(q) := \lambda(q)(\lambda(q) - q)$、$\lambda_i = \lambda(q_i)$ 和 $\kappa_i = \kappa(q_i)$。然后是 $\Sigma_S = \sum_{i \in S} \kappa_i h_i h_i^\top$、$b_S = \sum_{i \in S} \lambda_i h_i$，以及如 Eq. 11 所示，

$$\log \widetilde{L}(S) = \sum_{i \in S} \log \Phi(-q_i) - \frac{1}{2} \log\det(I_d + \Sigma_S) + \frac{1}{2} b_S^\top (I_d + \Sigma_S)^{-1} b_S. \tag{78}$$

我们现在对 Appendix C 的结果及其所依赖的假设进行概述。

C.1 概览 Appendix C

Appendix C.2 指出了结果所依赖的三个假设。第一个假设是，大多数候选人（主体）的质量独立地来自一个固定的有界分布，而少数候选人（尖峰）则具有高于所有主体质量的固定质量。换句话说，候选人群体中包含一些质量高于其他任何候选人的尖峰，而主体部分则由来自共同分布的较低质量候选人组成。第二个假设是，表示具有 $h_i = \rho v_i$，且在固定尺度 ρ 下具有 $\|v_i\|_2 \le 1$，与质量无关。因此 ρ 限制了两个候选人之间可能的相关性强度，因为 $\mathrm{Cov}(\mathbf{Z}_i, \mathbf{Z}_j \mid H) = h_i^\top h_j \le \rho^2$，如 Proposition 2 所示，候选人之间的相似度不携带关于其质量的信息。第三个假设仅在预算较大时需要。在此情况下，我们需在大小为 k 的集合族中最小化目标函数，且要求这些集合具有多样性，即它们的表示方向应覆盖所有方向，而非集中在少数方向上。

Appendix C.3 表明，在小预算情况下，当第 k 大与第 $(k{+}1)$ 大质量之间的差距（以 $\log \Phi(-q_{(k+1)}) - \log \Phi(-q_{(k)})$ 衡量）超过 $k\rho^2$ 的常数倍时，两个规则一致，该条件限制了 k 选取的探针所能累积的相关系数项。此时，代理贪婪规则将确切返回探针型规则的前 k 个候选集，且如果此条件在不超过 k 的每个预算下均成立，则也会以相同的顺序添加这些候选。

Appendix C.4 表明，在大预算情况下，PKTP 和 RepExp 几乎优化相同的目标。为了看清这一点，我们对第三种假设下的多种集合的主体质量，平均计算 PKTP 的目标值。除了一个常数项以及随 k 增大而减小的误差外，最小化该平均值等价于保持峰值并最大化 RepExp 目标。这是一个关于目标的声明，它并不意味着 PKTP 和 RepExp 选择的是同一组集合。

Appendix C.5 构造了一个显式模型，使得两个结论均成立。该模型固定了一个质量分布和一个相关系数尺度 ρ。在此模型中，代理贪婪规则对每个 $k \le 3$ 均遵循探测型规则，而大预算结果在 k 增长时依然成立。

C.2 假设

我们使用 k 表示选择预算，$1 \le k \le N$ 表示固定的候选池。以下三个假设涉及候选者的质量得分和表示。

(A1) **主体和尖峰**。存在一个固定的集合 $O = \{o_1, \dots, o_r\}$ 包含 $r \ge 1$ 个候选者，称为尖峰。其余所有候选者的质量从一个定义在固定区间 $[w_0, w] \subseteq [-M, M]$ 上的分布 $\mathcal{D}_q$ 中独立抽取，其中 M 为有限值。尖峰的质量是固定的，位于 $[-M, M]$ 内，并满足

$$q_{o_1} > q_{o_2} > \cdots > q_{o_r} > w, \tag{79}$$

因此，每个尖峰的品质都高于每一个批量候选者。

(A2) **相关系数尺度**。表示为 $h_i = \rho v_i$ 与 $\|v_i\|_2 \le 1$ 以及固定的 $0 < \rho \le 1$ 。它们是确定性的，因此不依赖于体内的品质。较小的 ρ 意味着候选者之间的相关性较弱，如 Proposition 2 所示。小预算结果需要 ρ 相对于品质差距较小，而大预算结果则允许 $\rho > 0$ 为任意固定值。

(A3) **多样化的表示**。对于较大的预算，我们让 $k \to \infty$ 沿着一系列候选池进行，这些候选池的大小为 $N_k \ge k$ ，而维度 d 、尖峰及其质量、尺度 ρ 以及分布 $\mathcal{D}_q$ 保持不变。大预算结果在族 $\mathcal{A}_k$ 上最小化目标函数，其中 $\mathcal{A}_k$ 是 $[N_k]$ 的所有大小为 k 的子集构成的集合，且满足如下性质：它是确定性的，并且独立于主体质量进行选取；对每个足够大的 k ，该族非空；并且每个 $S \in \mathcal{A}_k$ 均满足

$$c_0 k I_d \preceq \sum_{i \in S} v_i v_i^\top \preceq C_0 k I_d, \qquad \left\| \sum_{i \in S \setminus O} v_i \right\|_2 \le B_0, \tag{80}$$

其中 $c_0, C_0, B_0 > 0$ 不依赖于 k 或 S。第一个条件表明，S 中的表示覆盖了所有方向，且总权重随 k 线性增长；第二个条件表明，体候选者的表示几乎相互抵消。$\mathcal{A}_k$ 中的不同集合可能包含不同的尖峰。

C.3 小预算 k：质量差距导致探针式规则

本小节表明，当第 k 大与第 $(k+1)$ 大质量之间的差距相对于 $k\rho^2$ 较大时，PKTP 保持确切的前 k 个候选者，正如探测式规则一样。我们记

$$\Lambda := \max_{q \in [-M, M]} \lambda(q) < \infty \tag{81}$$

对于所有可能的品质中 λ 的最大值，该值对每个 λ_i 都构成上界。将实现的品质按顺序排列为 $q_{(1)} \ge \cdots \ge q_{(N)}$ ，并令 S_k^{top} 表示品质最大的 k 个候选者组成的集合。对于 $1 \le k < N$ ，定义

$$\Gamma_k := \log \Phi(-q_{(k+1)}) - \log \Phi(-q_{(k)}). \tag{82}$$

由于 $\frac{d}{dq} \log \Phi(-q) = -\lambda(q) < 0$ ，当且仅当 $\Gamma_k > 0$ 时，$q_{(k)} > q_{(k+1)}$ 。此差距衡量了用 S_k^{top} 之外最强的候选者替换其最弱成员所带来的质量损失。下一个引理指出，向一组 t 个候选者添加一个候选者 j 会使其目标值变化量等于其自身的失败项 $\log \Phi(-q_j)$ ，误差项随 t 增长，且在 $\rho \to 0$ 时消失。

Lemma 2. *在 (A1) 和 (A2) 下，若 $|S| = t$ 且 $j \notin S$，则*

$$\left|\log \widetilde{L}(S \cup \{j\}) - \log \widetilde{L}(S) - \log \Phi(-q_j)\right| \leq \frac{\rho^2}{2} + \Lambda^2 \left(t + \frac{1}{2}\right) \rho^2 + \frac{\Lambda^2 t^2 \rho^4}{2}. \tag{83}$$

证明. 我们首先记录 $0 < \kappa(q) < 1$。正性在 Appendix B.1.1 中得到证明。对于上界，令 $Z \sim N(0,1)$ 并回顾

$$\mathbb{E}[Z \mid Z > q] = \lambda(q), \qquad \mathbb{E}[Z^2 \mid Z > q] = 1 + q\lambda(q). \tag{84}$$

因此，条件方差为

$$0 < \mathrm{Var}(Z \mid Z > q) = 1 + q\lambda(q) - \lambda(q)^2 = 1 - \kappa(q). \tag{85}$$

令 $A = I_d + \Sigma_S$ ，$a_j = h_j^\top A^{-1} h_j$ ，以及 $u_j = h_j^\top A^{-1} b_S$ 。矩阵行列式引理和 Sherman–Morrison 公式给出

$$\det(A + \kappa_j h_j h_j^\top) = \det(A)(1 + \kappa_j a_j), \tag{86}$$

$$(A + \kappa_j h_j h_j^\top)^{-1} = A^{-1} - \frac{\kappa_j A^{-1} h_j h_j^\top A^{-1}}{1 + \kappa_j a_j}. \tag{87}$$

将二次项用 $b_{S\cup\{j\}} = b_S + \lambda_j h_j$ 展开后，随之得到

$$\log \widetilde{L}(S \cup \{j\}) - \log \widetilde{L}(S) = \log \Phi(-q_j) - \frac{1}{2}\log(1 + \kappa_j a_j) + \frac{\lambda_j u_j + \lambda_j^2 a_j/2 - \kappa_j u_j^2/2}{1 + \kappa_j a_j}. \tag{88}$$

由 (A2)，$\|h_j\|_2 \leq \rho$ ，并由 (A1)，$|q_i| \leq M$ ，因此 $\lambda_i \leq \Lambda$ 。由于 $A \succeq I_d$ ，我们得到 $0 \leq a_j \leq \rho^2$ 且

$$|u_j| \leq \|h_j\|_2 \|A^{-1}\|_{\mathrm{op}} \|b_S\|_2 \leq t\Lambda\rho^2. \tag{89}$$

使用 $\kappa_j < 1$ 和 $1 + \kappa_j a_j \geq 1$ 于 Eq. 88，$\log \Phi(-q_j)$ 的绝对修正值最多为

$$\frac{\rho^2}{2} + \Lambda(t\Lambda\rho^2) + \frac{\Lambda^2\rho^2}{2} + \frac{t^2\Lambda^2\rho^4}{2}, \tag{90}$$

其中，Eq. 83 是边界。 □

Theorem 3. *在 (A1) 和 (A2) 成立的条件下，若 $k\rho^2 \leq 1$ 且 $\Gamma_k > (1 + 3\Lambda^2)k\rho^2$ ，则 S_k^{top} 是 $\log \widetilde{L}$ 的唯一大小为 k 的最小化器，且代理贪心规则在 k 步后返回 S_k^{top} 。*

证明. 首先，注意到如果 $t \leq k - 1$ 且 $k\rho^2 \leq 1$ ，则 Lemma 2 的界乘以二满足

$$\rho^2 + \Lambda^2(2t + 1)\rho^2 + \Lambda^2 t^2 \rho^4 \leq k\rho^2 + 2\Lambda^2 k\rho^2 + \Lambda^2 k^2 \rho^4 \leq (1 + 3\Lambda^2)k\rho^2 < \Gamma_k. \tag{91}$$

对于任意 $i \in S_k^{\mathrm{top}}$、$j \notin S_k^{\mathrm{top}}$ 以及不包含 i, j 的公共电流集 S，引理 2 在 $|S| = t \leq k - 1$ 时给出，

$$\log \widetilde{L}(S \cup \{i\}) - \log \widetilde{L}(S \cup \{j\}) \leq \log \Phi(-q_i) - \log \Phi(-q_j) + (1 + 3\Lambda^2)k\rho^2 \tag{92}$$

$$\leq -\Gamma_k + (1 + 3\Lambda^2)k\rho^2 < 0. \tag{93}$$

如果当前的代理贪心规则集合包含于 S_k^{top}，那么在第 k 次选择之前，S_k^{top} 中至少有一个成员仍然可用。根据 Eq. 93，每个外部候选者都劣于一个可用的内部候选者。从空集出发，通过归纳法可证明前 k 次选择构成了 S_k^{top}。

对于全局最优性，取一个大小为 k 的集合 $R \neq S_k^{\mathrm{top}}$。存在 $j \in R \setminus S_k^{\mathrm{top}}$ 和 $i \in S_k^{\mathrm{top}} \setminus R$。应用 Eq. 93，其中 $S = R \setminus \{j\}$。将 j 替换为 i 会严格减小 $\log \widetilde{L}$，因此 R 不可能是优化器。这证明了最优集合的唯一性，即使 S_k^{top} 内部某些属性存在并列情况也是如此。 □

在每个预算值从 Theorem 3 到 k 时应用 Theorem 3，表明只要位置 k 之前的每一个间隔都足够大，代理贪婪规则也会按照探测式顺序添加这些候选者。这些尖峰提供了这样的间隔，从而得到以下推论。

Corollary 2. *在 (A1) 和 (A2) 成立的条件下，假设 $1 \le r < N$ 且定义*

$$\Gamma_* := \min\left(\{\log \Phi(-q_{o_{j+1}}) - \log \Phi(-q_{o_j}) : 1 \le j < r\} \cup \{\log \Phi(-w) - \log \Phi(-q_{o_r})\}\right) > 0. \tag{94}$$

若 $r\rho^2 \le 1$ 且 $(1 + 3\Lambda^2) r\rho^2 < \Gamma_*$，则对于体相性质的每一次实现，代理贪婪规则的前 r 次选择均按探测型规则选定的顺序为 $o_1, \ldots, o_r$。

证明. 所有整体性质最多为 w。因此，前 r 个候选者是有序的尖峰，且每个间隙 $\Gamma_1, \ldots, \Gamma_r$ 至少为 Γ_*。在每个预算 $k \le r$ 上分别应用定理 3。嵌套的前 k 个集合确定了完整的贪心顺序。 □

这些尖峰使得该结果在大规模池中依然具有意义。仅依靠整体品质时，随着池的增大，第 k 个和第 $(k+1)$ 个最大品质之间的差距通常会缩小，因此Theorem 3的条件最终会失效。尖峰周围的差距不依赖于整体，因此Corollary 2对每个池大小都成立，而整体品质则保持固定的方差。

C.4 大预算 k：期望目标简化为 RepExp 目标

我们现在固定 $\rho > 0$，让 k 增大。由于 $G_S = \rho^2 \sum_{i \in S} v_i v_i^\top$，(A3) 给出 $G_S \succeq c_0 \rho^2 k I_d$。因此，一个多样化集合的 Gram 矩阵在 k 上仍然呈线性增长，而较小的 ρ 仅通过因子 ρ^2 减缓这一增长。以下常数依赖于 ρ 以及 (A1)–(A3) 中的常数，因此本节的结果对每个固定的 ρ 随 $k \to \infty$ 而成立，但不必然在 ρ 随 k 增大时成立。定义常数

$$\overline{c} := \mathbb{E}_{q \sim \mathcal{D}_q} \log \Phi(-q), \qquad \overline{\lambda} := \mathbb{E}_{q \sim \mathcal{D}_q} \lambda(q), \qquad \overline{\kappa} := \mathbb{E}_{q \sim \mathcal{D}_q} \kappa(q), \qquad v_\lambda := \mathrm{Var}_{q \sim \mathcal{D}_q}(\lambda(q)). \tag{95}$$

这些期望值由于有界支撑而有限，且 $\overline{\kappa} > 0$ 由于 $\kappa(q) > 0$ 。

Theorem 4. *在条件 (A1)–(A3) 下，关于 $S \in \mathcal{A}_k$ 一致地，*

$$\mathbb{E} \log \widetilde{L}(S) = k\overline{c} + \sum_{o \in S \cap O} \left(\log \Phi(-q_o) - \overline{c}\right) + \frac{d\, v_\lambda}{2\overline{\kappa}} - \frac{1}{2} \log \det(I_d + \overline{\kappa} G_S) + O(k^{-1/2}). \tag{96}$$

期望是针对固定集合 S 的体性质而言的。

用文字表述,对体相性质进行平均后,一组多样化集合的目标仅通过其保留的尖峰以及 $\log\det(I_d+\overline{\kappa}G_S)$ 依赖于 S ，而所有其他项均为常数。该定理关注的是这种平均值，而非单次抽取体相性质时的 $\log\widetilde{L}(S)$ 。

证明. 固定 $S\in\mathcal{A}_k$ ，并写出 $J=S\cap O$ 和 $B=S\setminus O$ 。标量项的期望是确切的

$$\mathbb{E}\sum_{i\in S}\log\Phi(-q_i)=k\overline{c}+\sum_{o\in J}(\log\Phi(-q_o)-\overline{c}). \tag{97}$$

我们分别处理行列式和二次项。定义

$$G_B=\sum_{i\in B}h_ih_i^\top, \qquad \Sigma_J=\sum_{o\in J}\kappa(q_o)h_oh_o^\top, \qquad b_J=\sum_{o\in J}\lambda(q_o)h_o, \tag{98}$$

$$A_0=I_d+\overline{\kappa}G_B+\Sigma_J, \qquad \Delta=\sum_{i\in B}(\kappa(q_i)-\overline{\kappa})h_ih_i^\top, \qquad A=I_d+\Sigma_S=A_0+\Delta. \tag{99}$$

最多有 r 个尖峰贡献。将它们从 G_S 中移除会使它的算子范数最多改变 $r\rho^2$ ，因此对于所有充分大的 k ，有 $G_B\succeq c_1kI_d$ ，其中 $c_1>0$ 依赖于固定的 ρ 。质量区间的紧性给出了每个 $\kappa(q_i)$ 的正下界。因此 A ， A_0 以及它们连线段上的每矩阵的最小特征值至少为 c_2k 。

行列式项。 独立性和中心化消除了平方 Frobenius 范数中的交叉项，得到

$$\mathbb{E}\Delta=0, \qquad \mathbb{E}\|\Delta\|_F^2=\mathrm{Var}_{q\sim\mathcal{D}_q}(\kappa(q))\sum_{i\in B}\|h_i\|_2^4=O(k). \tag{100}$$

对于 $A_t=A_0+t\Delta$ ，微分得

$$\frac{d}{dt}\log\det A_t=\mathrm{tr}(A_t^{-1}\Delta), \qquad \frac{d^2}{dt^2}\log\det A_t=-\mathrm{tr}(A_t^{-1}\Delta A_t^{-1}\Delta). \tag{101}$$

绝对二阶导数至多为 $\|A_t^{-1}\|_{\mathrm{op}}^2\|\Delta\|_F^2\le Ck^{-2}\|\Delta\|_F^2$。因此，泰勒公式和Eq. 100推出

$$\mathbb{E}\log\det A=\log\det A_0+O(k^{-1}). \tag{102}$$

此外， $A_0-(I_d+\overline{\kappa}G_S)=\sum_{o\in J}(\kappa(q_o)-\overline{\kappa})h_oh_o^\top$ 具有有界范数。使用逆范数 $O(k^{-1})$ 的相同线段导数恒等式，可得

$$\log\det A_0=\log\det(I_d+\overline{\kappa}G_S)+O(k^{-1}). \tag{103}$$

二次项。 分解

$$b_S=\overline{b}+\zeta, \qquad \overline{b}=b_J+\overline{\lambda}\sum_{i\in B}h_i, \qquad \zeta=\sum_{i\in B}(\lambda(q_i)-\overline{\lambda})h_i. \tag{104}$$

由平衡性和有界尖峰贡献（假设 (A1) 和 (A3)），$\|\overline{b}\|=O(1)$。独立性给出 $\mathbb{E}\zeta=0$ 和 $\mathbb{E}\zeta\zeta^\top=v_\lambda G_B$。因此，

$$\mathbb{E}[b_S^\top A_0^{-1}b_S]=\overline{b}^\top A_0^{-1}\overline{b}+v_\lambda\,\mathrm{tr}(A_0^{-1}G_B)=\frac{d\,v_\lambda}{\overline{\kappa}}+O(k^{-1}). \tag{105}$$

对于最后一个等式，第一项是 $O(k^{-1})$ 且

$$A_0^{-1}G_B = \frac{1}{\overline{\kappa}}\big(I_d - A_0^{-1}(I_d + \Sigma_J)\big). \tag{106}$$

仍需将 A_0^{-1} 替换为相关的随机逆 A^{-1}。再生核恒等式给出 $A^{-1} - A_0^{-1} = -A^{-1}\Delta A_0^{-1}$。此外，$\mathbb{E}\|b_S\|_2^4 = O(k^2)$。为了验证此最后一个估计，将 ζ 的每个坐标写成独立的中心化有界变量之和 X_i。将其四次方展开得

$$\mathbb{E}\left(\sum_i X_i\right)^4 = \sum_i \mathbb{E}X_i^4 + 6\sum_{i<j}\mathbb{E}X_i^2\mathbb{E}X_j^2 = O(k^2). \tag{107}$$

只有 d 个坐标，以及 $(\sum_{a=1}^d z_a^2)^2 \le d\sum_{a=1}^d z_a^4$ ，因此得到向量估计；加入 $\overline{b} = O(1)$ 不会改变其顺序。由柯西-施瓦茨不等式可得

$$\mathbb{E}\left|b_S^\top(A^{-1} - A_0^{-1})b_S\right| \le \frac{C}{k^2}\mathbb{E}[\|b_S\|_2^2\|\Delta\|_F] \le \frac{C}{k^2}\sqrt{\mathbb{E}\|b_S\|_2^4\,\mathbb{E}\|\Delta\|_F^2} = O(k^{-1/2}). \tag{108}$$

将 Eq. 97–Eq. 108 与 Eq. 78 相结合，即可证明该定理。所有界限仅使用了 (A1)–(A3) 中的公共常数，因此误差在 $\mathcal{A}_k$ 上是一致的。 □

罚项不会消失，但平均而言，它对每个不同的集合都贡献相同的常数 $d\,v_\lambda/(2\overline{\kappa})$。相比之下，Eq. 96 中的尖峰项取决于 S 保留哪些尖峰，因此在仍需选择尖峰的情况下，该项不能被忽略。

当大预算优化器包含尖峰时。 Theorem 4 保存集合中包含的任意尖峰。为了证明最优集合会保留所有尖峰，我们需要对 $\mathcal{A}_k$ 再增加一个条件，即缺失的尖峰总是可以与一个冗余候选者进行交换。

Definition 4 (Closure under insertion of a missing spike)**.** *一个大小为 k 的子集族 $\mathcal{A}_k$ 具有所需的闭包性质，当且仅当对任意 $S \in \mathcal{A}_k$ 和 $o \in O \setminus S$，均存在一个整体候选元 $i \in S \setminus O$，使得*

$$S' = (S \setminus \{i\}) \cup \{o\} \in \mathcal{A}_k. \tag{109}$$

此条件仅要求对每个缺失的尖峰存在一个允许的替换。对于仅由多样性条件定义的族而言，这并不自动成立，而 Appendix C.5 给出一个满足该条件的具体族。

Lemma 3 (The averaged objective keeps the spikes)**.** *假设 $r \ge 1$, 每个尖峰具有固定的质量 $q_o > w$, 且 $\mathcal{A}_k$ 满足定义 4。在定理 4 的假设下，$\mathbb{E}\log\widetilde{L}(S)$ 在 $S \in \mathcal{A}_k$ 上的每一个极小化元对所有充分大的 k 均包含 O 的全部。*

证明. 我们首先界定了单次替换对对数行列式的影响。假设 $S' = (S \setminus \{i\}) \cup \{o\}$ ，其中 i 为体元候选，且两者均满足 $S, S' \in \mathcal{A}_k$ 。固定 $\nu > 0$ 并设

$$A(t) = I_d + \nu\big((1-t)G_S + tG_{S'}\big), \qquad 0 \le t \le 1. \tag{110}$$

均匀协方差下界给出 $A(t) \succeq (1 + \nu c k)I_d$ 对于某个固定的 $c > 0$ 。此外 $G_{S'} - G_S = h_o h_o^\top - h_i h_i^\top$ ，所以

$$\left|\frac{d}{dt}\log\det A(t)\right| = \nu\left|h_o^\top A(t)^{-1}h_o - h_i^\top A(t)^{-1}h_i\right| \le \frac{\nu(\|h_o\|_2^2 + \|h_i\|_2^2)}{1 + \nu c k} \le \frac{2\nu\rho^2}{1 + \nu c k}. \tag{111}$$

对 $t \in [0,1]$ 积分表明，在允许的替换下具有一致性，

$$|\log\det(I_d + \nu G_{S'}) - \log\det(I_d + \nu G_S)| = O(k^{-1}). \tag{112}$$

回想一下 $\bar{c} = \mathbb{E}_{q\sim\mathcal{D}_q} \log\Phi(-q)$。由于在 $q \sim \mathcal{D}_q$ 下 $q \le w < q_o$ 几乎必然成立，且 $q \mapsto \log\Phi(-q)$ 严格递减，

$$\eta := \min_{o\in O}\big(\bar{c} - \log\Phi(-q_o)\big) > 0. \tag{113}$$

集合 O 是有限的，因此该极小点是一个固定的正数。如果 S 未能包含尖峰 o ，则选择由闭包条件提供的替代方案。定理 4 和 Eq. 112 中的展开式，结合 $\nu = \overline{\kappa}$ ，给出

$$\mathbb{E}\log\widetilde{L}(S') - \mathbb{E}\log\widetilde{L}(S) = \log\Phi(-q_o) - \bar{c} - \frac{1}{2}\left[\log\det(I_d + \overline{\kappa}G_{S'}) - \log\det(I_d + \overline{\kappa}G_S)\right] + O(k^{-1/2}) \tag{114}$$

$$\le -\eta + O(k^{-1/2}) < 0 \tag{115}$$

对于所有足够大的 k。该阈值在该族中是统一的。因此，任何极小化器都不能忽略一个尖峰。 □

一旦保留所有尖峰，每个剩余集合的尖峰项都相同，因此最小化平均值等价于最大化对数行列式。下一推论使这一点更加明确。

Corollary 3. 令 $\mathcal{A}_k^O = \{S \in \mathcal{A}_k : O \subseteq S\}$ ，对于 $\nu > 0$ ，令

$$D_\nu(S) = \log\det(I_d + \nu G_S), \qquad S_k^{\det}(\nu) \in \arg\max_{S\in\mathcal{A}_k^O} D_\nu(S). \tag{116}$$

在假设 Lemma 3 下，令 $\widehat{S}_k^{\log}$ 在 $\mathcal{A}_k$ 上最小化 $\mathbb{E}\log\widetilde{L}(S)$。则对于所有充分大的 k，

$$0 \le D_{\overline{\kappa}}(S_k^{\det}(\overline{\kappa})) - D_{\overline{\kappa}}(\widehat{S}_k^{\log}) = O(k^{-1/2}). \tag{117}$$

证明. Lemma 3 将每个优化器置于 $\mathcal{A}_k^O$ 对所有足够大的 k 。在此族上，定理 4 具有如下形式

$$\mathbb{E}\log\widetilde{L}(S) = C_k - \tfrac{1}{2}D_{\overline{\kappa}}(S) + e_k(S), \qquad \sup_{S\in\mathcal{A}_k^O}|e_k(S)| \le Ck^{-1/2}, \tag{118}$$

其中 C_k 与 S 相互独立。$\widehat{S}_k^{\log}$ 相对于 $S_k^{\det}(\overline{\kappa})$ 的最优性意味着

$$\tfrac{1}{2}\big[D_{\overline{\kappa}}(S_k^{\det}(\overline{\kappa})) - D_{\overline{\kappa}}(\widehat{S}_k^{\log})\big] \le e_k(S_k^{\det}(\overline{\kappa})) - e_k(\widehat{S}_k^{\log}) \le 2Ck^{-1/2}. \tag{119}$$

这证明了 Eq. 117。 □

由于 $D_{\overline{\kappa}}$ 是带有 $\tau = 1/\overline{\kappa}$ (Appendix A.3) 的 RepExp 目标，因此平均目标的最小化器几乎在保持所有尖峰的前提下，最大化不同集合中的 RepExp 目标。

C.5 一个包含两种状态的显式模型

本小节构建了一个显式模型，使得假设 Appendix C.3 和 Appendix C.4 在同一个固定的品质分布和一个固定的 ρ 下同时成立。令 N 表示候选池的总大小，并考虑一个嵌套的池序列 $N \to \infty$。每个池包含相同的三个尖峰 $O = \{o_1, o_2, o_3\}$，其索引为 $\{1, 2, 3\}$，以及一个大小为 $N - 3$ 的主体集合 $\mathcal{B}_N = [N] \setminus O$。这些池可以通过取一个无限的主体候选人序列，并令 $\mathcal{B}_N$ 包含其前 $N - 3$ 个成员来关联。在整个构造过程中，维度 d 保持固定。对于大预算情形，固定任意指数 $\alpha \in (0, 1)$，并定义整数值的预算调度

$$k(N) := \lfloor N^{\alpha} \rfloor . \tag{120}$$

然后令 $k(N) \to \infty$ 和 $k(N)/N \to 0$ 如 $N \to \infty$ ，而 $3 \le k(N) \le N - 3$ 对所有足够大的 N 成立。在此构造的小预算部分中，$k \in \{1, 2, 3\}$ 表示一个固定的选样预算，而 $k(N)$ 是大预算情形中使用的预算。我们首先选择质量分布，然后固定公共尺度 ρ ，最后构建增长的样本池及其族 $\mathcal{A}_k$ 。

For the quality model in (A1), draw the bulk qualities independently from $\mathcal{D}_q = \mathrm{Unif}[-\gamma, \gamma]$, once for the nested sequence of pools, and let the three spike qualities be

$$q_{o_1} = 4\gamma, \qquad q_{o_2} = 3\gamma, \qquad q_{o_3} = 2\gamma. \tag{121}$$

此处 $\gamma > 0$ 为一个固定常数。因此我们可以取 $w_0 = -\gamma$ 、$w = \gamma$ 和 $M = 4\gamma$ 。每个尖峰的品质均严格高于整个主体品质分布。

$$\mathrm{Var}_{q \sim \mathcal{D}_q}(q) = \frac{\gamma^2}{3} > 0. \tag{122}$$

特别是，当 N 增大时，主体性质保持固定的、非零的方差。

接下来，考虑小预算下的质量差距。由于 $q \mapsto \log \Phi(-q)$ 是严格递减的，因此数量

$$\Gamma_* = \min\big\{\log \Phi(-3\gamma) - \log \Phi(-4\gamma),\, \log \Phi(-2\gamma) - \log \Phi(-3\gamma),\, \log \Phi(-\gamma) - \log \Phi(-2\gamma)\big\} \tag{123}$$

是严格正的。这些间隙与体候选数无关，因为没有任何体候选的质量高于 γ 。更明确地，由于 $\frac{d}{dq} \log \Phi(-q) = -\lambda(q)$ 且 $\lambda'(q) = \kappa(q) > 0$ ，每个差值在该极小点处是 λ 在长度为 γ 且包含于 $[\gamma, 4\gamma]$ 的区间上的积分。因此，

$$\Gamma_* \ge \gamma \lambda(\gamma) > 0. \tag{124}$$

令 $\Lambda = \max_{q \in [-4\gamma, 4\gamma]} \lambda(q)$ ，并选择固定的尺度 $\rho > 0$ ，使得

$$0 < \rho^2 < \min\left\{\frac{1}{3},\, \frac{\Gamma_*}{3(1 + 3\Lambda^2)}\right\}. \tag{125}$$

取满足 $\|v_i\|_2 \le 1$ 的确定性向量 v_i ，并设 $h_i = \rho v_i$ ，如 (A2) 所要求。此选择给出

$$3\rho^2 \le 1, \qquad 3(1 + 3\Lambda^2)\rho^2 < \Gamma_*. \tag{126}$$

对于每个 $N > 3$ 以及体相性质的每一次实现，Corollary 2 均适用，因此前三个贪婪选择依次为 o_1, o_2, o_3。对于每个固定的 $k \in \{1, 2, 3\}$，Theorem 3 同样表明集合 $\{o_1, \ldots, o_k\}$ 是 $\log \widetilde{L}$ 的唯一大小为 k 的极小化集。因此，小预算结论在池大小 N 增大时依然一致成立。

对于大预算部分，我们首先描述一种获得满足定义 4 闭包性质的集合族的一般方法。令 $\mathcal{C}_k$ 为任意非空的仅包含整体大小为 k 的确定性集合族，且对于与 k 无关的固定常数 $B_{\mathrm{core}}, c_{\mathrm{core}}, C_{\mathrm{core}} > 0$ ，

$$\left\| \sum_{i \in U} v_i \right\|_2 \le B_{\mathrm{core}}, \qquad c_{\mathrm{core}} k I_d \preceq \sum_{i \in U} v_i v_i^\top \preceq C_{\mathrm{core}} k I_d, \qquad U \in \mathcal{C}_k. \tag{127}$$

如前所述，$h_i = \rho v_i$ 与 $\|v_i\|_2 \le 1$ 一同变化，而 $\rho > 0$ 保持固定。定义

$$\mathcal{A}_k = \{(U \setminus R) \cup J : U \in \mathcal{C}_k,\ J \subseteq O,\ R \subseteq U,\ |R| = |J|\}. \tag{128}$$

如果 $S = (U \setminus R) \cup J$ 丢失了一个尖峰 o ，将任意一个 $i \in U \setminus R$ 替换为 o 可以得到与 $R \cup \{i\}$ 和 $J \cup \{o\}$ 相同的表示。因此，该族在定义 4 意义下是封闭的，对于 $k \ge r$ 。此外，由于最多移除或插入 r 个向量，

$$\left\| \sum_{i \in S \setminus O} h_i \right\|_2 \le \rho(B_{\mathrm{core}} + r), \tag{129}$$

$$\rho^2(c_{\mathrm{core}} k - r) I_d \preceq G_S \preceq \rho^2(C_{\mathrm{core}} k + r) I_d. \tag{130}$$

对于矩阵界，每个被移除或插入的向量使用 $0 \preceq v_i v_i^\top \preceq I_d$ 。对于所有充分大的 k ，这些条件意味着 (A3)，例如取 $B_0 = B_{\mathrm{core}} + r$ ，$c_0 = c_{\mathrm{core}}/2$ ，以及 $C_0 = C_{\mathrm{core}} + 1$ 。

我们现在从对径对构造这样的核心族。令体方向属于 $\{\pm e_1, \dots, \pm e_d\}$ ，其中 $e_1, \dots, e_d$ 为标准基向量。一个对径对由两个不同候选者组成，其方向分别为 e_j 和 $-e_j$ 。它对向量和与 Gram 矩阵的贡献分别为

$$e_j + (-e_j) = 0, \qquad e_j e_j^\top + (-e_j)(-e_j)^\top = 2 e_j e_j^\top. \tag{131}$$

因此，配对抵消了向量和，同时在方向 e_j 保持了协方差

Write $b_\ell := 3 + \ell$ for the ℓth candidate in the infinite bulk sequence, and assign the directions of $b_1, b_2, \dots$ in the repeating order

$$e_1, -e_1, e_2, -e_2, \dots, e_d, -e_d, e_1, -e_1, \dots. \tag{132}$$

因此 $\mathcal{B}_N = \{b_1, \dots, b_{N-3}\}$ 。方向是确定性的，且与随机量的实现无关，而尖峰方向可以是任意范数不超过一的确定性向量。对于所有充分大的 N ，通过定义仅包含主体部分的核心及其单例族来

$$U_N := \{b_1, \dots, b_{k(N)}\}, \qquad \mathcal{C}_N := \{U_N\}. \tag{133}$$

Then $|U_N| = k(N)$. Let $n_{N,j}$ denote the number of complete antipodal pairs on axis j among the first $2\lfloor k(N)/2 \rfloor$ members of U_N. If $k(N)$ is even, U_N consists entirely of these pairs, and the cyclic construction gives

$$2 \sum_{j=1}^{d} n_{N,j} = k(N), \qquad n_{N,j} \ge \frac{k(N)}{4d} \quad \text{for every } j \tag{134}$$

对于所有足够大的 N。下界意味着在每条轴上至少有 $1/(2d)$ 比例的选定向量位于其上。在这种情况下，

$$\sum_{i\in U_N} v_i = 0, \qquad \frac{k(N)}{2d} I_d \preceq \sum_{i\in U_N} v_i v_i^\top = 2\,\mathrm{diag}(n_{N,1},\dots,n_{N,d}) \preceq k(N) I_d. \tag{135}$$

如果 $k(N)$ 为奇数，则其前 $k(N)-1$ 个成员构成了 $n_{N,j}$ 所统计的完整配对，且这些计数满足

$$2\sum_{j=1}^{d} n_{N,j} = k(N)-1, \qquad n_{N,j} \geq \frac{k(N)-1}{4d} \tag{136}$$

for all sufficiently large N. The remaining member has direction e_{j_N} for an axis $j_N \in \{1,\dots,d\}$ determined by the cyclic ordering. Thus

$$\left\| \sum_{i\in U_N} v_i \right\|_2 = 1, \qquad \frac{k(N)-1}{2d} I_d \preceq \sum_{i\in U_N} v_i v_i^\top \preceq k(N) I_d. \tag{137}$$

因此，对于两种奇偶性以及所有充分大的 N，核心族界成立且常数固定

$$B_{\mathrm{core}} = 1, \qquad c_{\mathrm{core}} = \frac{1}{4d}, \qquad C_{\mathrm{core}} = 1. \tag{138}$$

将该核心族如Eq. 128所示扩大，使用 $r=3$，得到一族 $\mathcal{A}_N^{\mathrm{con}}$ 大小为 $k(N)$ 的 $[N]$ 子集，该族在缺失尖峰插入时是封闭的。根据Eqs. 129 and 130，对于所有足够大的 N，它满足（A3），其中 $B_0 = 4$、$c_0 = 1/(8d)$ 和 $C_0 = 2$。在将一般的大预算结果应用于此构造时，其预算参数 k 被实例化为 $k(N)$。为了恢复通用的预算索引记号，设

$$N_k := \left\lceil k^{1/\alpha} \right\rceil, \qquad \mathcal{A}_k := \mathcal{A}_{N_k}^{\mathrm{con}}. \tag{139}$$

对于 $0<\alpha<1$ ，此选择对所有充分大的 k 均满足 $\lfloor N_k^\alpha \rfloor = k$ 和 $N_k \geq k+3$ 。

因此，Lemma 3 成立，所以对于所有充分大的 N，$\mathbb{E}\log \widetilde{L}(S)$ 在 $\mathcal{A}_N^{\mathrm{con}}$ 上的每个极小化元都包含这三个尖峰，且 Corollary 3 成立。

总而言之，一个固定的品质分布和一个固定的 ρ 同时适用于两种情形。对于每个 $k \leq 3$，阶数为 $(1+3\Lambda^2)k\rho^2$ 的相关系数项均低于固定的间隙 Γ_*，因此代理贪心规则对每个池大小都遵循探测型规则。随着 $k(N)\to\infty$，$\mathcal{A}_N^{\mathrm{con}}$ 中每个集合的 Gram 矩阵按 $k(N)\rho^2$ 增长，Appendix C.4 的结果适用，而保留的池比例 $k(N)/N$ 趋于零。

D 基准-分层结果来自 Section 4.2

本节报告了Fig. 3背后的数字。Table 1针对每个模型，汇总了所有测试问题上的每种剪枝策略的 pass@k ，Tables 2 to 9则按基准分别列出这些结果，每个模型对应一张表格。所有表格均采用Section 4.1的情景，包含 $N = 128$ 次回溯的池化，$T = 4000$ 个 token 的截止值以及重复 20 次的八重交叉验证。每个条目为重复实验中 pass@k 的平均值（以百分比表示），括号内的数值为其在重复实验中的标准差。

表 1: Pass@k (%)，按问题汇总。

Qwen3-0.6B

	@1	@2	@4	@8	@16
Random (Pass@k)	24.0 (0.00)	34.4 (0.00)	45.4 (0.00)	56.5 (0.00)	67.6 (0.00)
Linear Probe	24.9 (0.27)	33.8 (0.25)	44.3 (0.21)	56.2 (0.30)	67.1 (0.27)
RepExp	23.9 (0.12)	33.5 (0.10)	45.0 (0.08)	55.9 (0.08)	67.0 (0.06)
PKTP	25.6 (0.29)	36.3 (0.22)	47.2 (0.29)	58.4 (0.31)	69.3 (0.28)

Qwen3-1.7B

	@1	@2	@4	@8	@16
Random (Pass@k)	39.5 (0.00)	51.5 (0.00)	62.6 (0.00)	72.5 (0.00)	81.0 (0.00)
Linear Probe	40.7 (0.28)	52.0 (0.24)	63.1 (0.27)	72.5 (0.18)	79.9 (0.20)
RepExp	39.6 (0.08)	51.6 (0.08)	63.9 (0.07)	74.6 (0.04)	82.2 (0.03)
PKTP	39.3 (0.35)	52.7 (0.29)	64.4 (0.24)	73.8 (0.23)	81.7 (0.21)

OpenMath-Nemotron-1.5B

	@1	@2	@4	@8	@16
Random (Pass@k)	47.1 (0.00)	59.3 (0.00)	69.3 (0.00)	77.3 (0.00)	83.9 (0.00)
Linear Probe	48.2 (0.26)	59.8 (0.23)	69.4 (0.26)	77.6 (0.18)	84.0 (0.16)
RepExp	47.3 (0.06)	57.9 (0.07)	68.9 (0.05)	76.8 (0.05)	84.7 (0.03)
PKTP	48.1 (0.32)	59.4 (0.28)	69.4 (0.20)	78.3 (0.19)	85.2 (0.17)

DeepSeek-R1-Distill-Qwen-1.5B

	@1	@2	@4	@8	@16
Random (Pass@k)	27.4 (0.00)	38.4 (0.00)	49.5 (0.00)	60.2 (0.00)	70.3 (0.00)
Linear Probe	30.1 (0.22)	39.8 (0.21)	49.9 (0.20)	59.4 (0.22)	69.7 (0.24)
RepExp	27.3 (0.08)	38.5 (0.07)	49.8 (0.04)	60.6 (0.06)	72.6 (0.03)
PKTP	30.3 (0.28)	41.4 (0.18)	52.9 (0.28)	62.5 (0.21)	71.7 (0.23)

Qwen3-8B

	@1	@2	@4	@8	@16
Random (Pass@k)	46.9 (0.00)	58.0 (0.00)	67.2 (0.00)	75.2 (0.00)	82.3 (0.00)
Linear Probe	49.2 (0.35)	59.2 (0.28)	67.4 (0.23)	74.4 (0.20)	81.2 (0.19)
RepExp	46.9 (0.09)	57.4 (0.06)	68.1 (0.07)	75.9 (0.04)	83.0 (0.04)
PKTP	47.3 (0.23)	58.7 (0.33)	68.6 (0.29)	76.0 (0.22)	83.0 (0.26)

OpenMath-Nemotron-7B

	@1	@2	@4	@8	@16
Random (Pass@k)	44.0 (0.00)	55.5 (0.00)	66.0 (0.00)	75.2 (0.00)	83.1 (0.00)
Linear Probe	46.3 (0.21)	57.5 (0.22)	67.5 (0.23)	76.3 (0.16)	83.6 (0.17)
RepExp	44.0 (0.11)	56.8 (0.07)	66.4 (0.07)	76.3 (0.04)	84.7 (0.05)
PKTP	47.4 (0.29)	59.1 (0.35)	68.2 (0.29)	76.7 (0.24)	84.3 (0.21)

DeepSeek-R1-精简-Qwen-7B

	@1	@2	@4	@8	@16
Random (Pass@k)	37.5 (0.00)	48.3 (0.00)	58.5 (0.00)	68.2 (0.00)	77.5 (0.00)
Linear Probe	37.4 (0.17)	46.7 (0.27)	56.4 (0.25)	66.0 (0.22)	76.6 (0.32)
RepExp	37.4 (0.08)	47.2 (0.08)	58.6 (0.07)	70.0 (0.04)	79.7 (0.04)
PKTP	38.6 (0.27)	49.5 (0.24)	59.7 (0.25)	70.0 (0.31)	79.3 (0.28)

Skywork-OR1-数学-7B

	@1	@2	@4	@8	@16
Random (Pass@k)	42.5 (0.00)	53.1 (0.00)	62.7 (0.00)	71.5 (0.00)	79.8 (0.00)
Linear Probe	44.4 (0.24)	54.2 (0.22)	62.9 (0.18)	71.3 (0.29)	79.4 (0.22)
RepExp	42.5 (0.09)	54.5 (0.09)	64.5 (0.06)	72.1 (0.04)	79.4 (0.05)
PKTP	44.7 (0.34)	55.7 (0.22)	65.6 (0.26)	73.2 (0.29)	80.3 (0.22)

表 2: 每基准通过率 @k (%)，Qwen3-0.6B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	23.2 (0.00)	33.8 (0.00)	45.5 (0.00)	58.3 (0.00)	71.2 (0.00)
Linear Probe	26.6 (0.70)	35.6 (0.61)	43.6 (0.84)	56.5 (0.89)	72.5 (0.79)
RepExp	23.3 (0.28)	29.5 (0.23)	41.4 (0.20)	53.7 (0.22)	66.5 (0.15)
PKTP	25.2 (1.07)	36.7 (1.01)	50.2 (1.11)	64.2 (0.79)	75.5 (0.78)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	20.8 (0.00)	29.9 (0.00)	39.9 (0.00)	50.8 (0.00)	62.1 (0.00)
Linear Probe	27.1 (0.68)	33.3 (0.84)	43.0 (0.69)	49.9 (0.60)	60.5 (0.60)
RepExp	20.3 (0.24)	30.9 (0.25)	39.1 (0.20)	47.7 (0.20)	60.0 (0.14)
PKTP	26.3 (0.95)	39.0 (0.75)	48.5 (0.83)	55.0 (0.52)	63.4 (0.56)

超越 AIME

	@1	@2	@4	@8	@16
Random (Pass@k)	11.7 (0.00)	19.5 (0.00)	29.6 (0.00)	41.2 (0.00)	54.2 (0.00)
Linear Probe	15.9 (0.76)	22.6 (0.76)	34.1 (0.86)	44.3 (1.09)	52.0 (0.89)
RepExp	11.7 (0.28)	19.2 (0.22)	30.8 (0.24)	44.8 (0.22)	58.8 (0.14)
PKTP	12.8 (0.72)	19.2 (0.76)	28.0 (0.76)	41.2 (1.02)	54.8 (0.68)

奥数数学（简单）

	@1	@2	@4	@8	@16
Random (Pass@k)	13.3 (0.00)	21.4 (0.00)	31.7 (0.00)	44.0 (0.00)	57.8 (0.00)
Linear Probe	13.1 (0.55)	19.6 (0.63)	29.0 (0.68)	41.2 (0.74)	53.0 (0.87)
RepExp	13.4 (0.18)	21.2 (0.18)	31.6 (0.18)	42.3 (0.21)	58.5 (0.15)
PKTP	13.3 (0.51)	19.5 (0.71)	28.5 (0.77)	43.1 (1.11)	59.7 (0.80)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	28.3 (0.00)	39.4 (0.00)	50.2 (0.00)	59.7 (0.00)	68.8 (0.00)
Linear Probe	27.1 (0.63)	36.7 (0.77)	48.4 (0.41)	60.9 (0.61)	70.1 (0.51)
RepExp	28.0 (0.20)	39.7 (0.17)	52.6 (0.12)	59.8 (0.11)	67.1 (0.10)
PKTP	28.7 (0.72)	40.2 (0.72)	52.5 (0.75)	62.5 (0.41)	71.9 (0.58)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	38.9 (0.00)	53.0 (0.00)	65.5 (0.00)	76.0 (0.00)	84.3 (0.00)
Linear Probe	36.5 (0.60)	49.9 (0.66)	61.6 (0.55)	75.7 (0.72)	86.1 (0.50)
RepExp	38.9 (0.28)	50.9 (0.20)	63.3 (0.21)	77.2 (0.11)	84.2 (0.08)
PKTP	41.0 (0.86)	56.5 (0.69)	67.6 (0.49)	76.5 (0.41)	83.2 (0.41)

表 3: 每基准测试通过率 @k (%)，Qwen3-1.7B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	47.0 (0.00)	59.6 (0.00)	70.4 (0.00)	78.9 (0.00)	85.4 (0.00)
Linear Probe	51.7 (0.60)	63.3 (0.65)	73.2 (0.56)	81.0 (0.57)	87.3 (0.31)
RepExp	47.4 (0.21)	60.7 (0.23)	72.2 (0.19)	85.6 (0.09)	90.6 (0.07)
PKTP	44.0 (0.96)	58.3 (0.62)	71.5 (0.57)	80.3 (0.44)	87.2 (0.41)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	41.9 (0.00)	52.4 (0.00)	62.7 (0.00)	72.7 (0.00)	82.2 (0.00)
Linear Probe	45.8 (0.58)	56.0 (0.63)	62.1 (0.48)	69.9 (0.51)	78.1 (0.63)
RepExp	41.7 (0.21)	51.7 (0.22)	64.2 (0.18)	76.7 (0.18)	85.2 (0.09)
PKTP	42.7 (0.83)	54.8 (0.91)	66.6 (0.67)	74.7 (0.51)	82.1 (0.65)

超越 AIME

	@1	@2	@4	@8	@16
Random (Pass@k)	35.0 (0.00)	45.7 (0.00)	55.8 (0.00)	65.8 (0.00)	75.7 (0.00)
Linear Probe	34.2 (0.67)	44.4 (0.81)	55.6 (0.88)	65.9 (0.60)	76.2 (0.60)
RepExp	34.9 (0.23)	41.6 (0.24)	55.2 (0.14)	66.7 (0.14)	77.3 (0.09)
PKTP	32.0 (0.79)	43.7 (0.70)	54.3 (0.74)	65.2 (0.61)	76.0 (0.75)

奥数数学（简单）

	@1	@2	@4	@8	@16
Random (Pass@k)	42.4 (0.00)	57.5 (0.00)	71.3 (0.00)	81.8 (0.00)	89.6 (0.00)
Linear Probe	41.8 (0.54)	56.1 (0.70)	72.3 (0.65)	84.2 (0.51)	89.7 (0.33)
RepExp	42.6 (0.19)	56.6 (0.18)	71.3 (0.14)	79.7 (0.10)	89.0 (0.09)
PKTP	42.9 (0.71)	59.2 (0.84)	73.4 (0.56)	84.5 (0.46)	91.4 (0.37)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	31.9 (0.00)	42.0 (0.00)	51.8 (0.00)	61.2 (0.00)	70.3 (0.00)
Linear Probe	27.8 (0.44)	38.5 (0.56)	49.7 (0.53)	59.5 (0.25)	66.4 (0.50)
RepExp	31.9 (0.17)	44.2 (0.16)	55.1 (0.11)	64.4 (0.09)	70.1 (0.08)
PKTP	31.3 (0.70)	42.1 (0.41)	51.2 (0.38)	61.2 (0.47)	70.2 (0.26)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	41.5 (0.00)	54.2 (0.00)	65.8 (0.00)	76.3 (0.00)	84.9 (0.00)
Linear Probe	48.8 (0.70)	58.9 (0.52)	68.6 (0.64)	76.3 (0.65)	84.6 (0.40)
RepExp	41.6 (0.24)	55.8 (0.20)	66.4 (0.19)	76.9 (0.16)	85.0 (0.10)
PKTP	45.7 (0.76)	60.8 (0.59)	72.3 (0.65)	79.2 (0.48)	85.4 (0.55)

表 4: 每个基准的 pass@k (%)，OpenMath-Nemotron-1.5B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	59.1 (0.00)	72.1 (0.00)	80.8 (0.00)	86.2 (0.00)	90.1 (0.00)
Linear Probe	63.5 (0.68)	75.4 (0.43)	83.3 (0.45)	89.1 (0.37)	92.1 (0.25)
RepExp	59.1 (0.17)	70.7 (0.15)	77.6 (0.11)	84.7 (0.10)	91.6 (0.06)
PKTP	62.1 (0.61)	74.1 (0.75)	82.3 (0.41)	85.9 (0.33)	89.9 (0.36)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	41.3 (0.00)	51.2 (0.00)	60.5 (0.00)	69.1 (0.00)	76.9 (0.00)
Linear Probe	45.5 (0.60)	55.2 (0.69)	63.9 (0.69)	71.6 (0.59)	77.4 (0.35)
RepExp	41.5 (0.26)	51.5 (0.24)	63.7 (0.16)	72.2 (0.15)	80.0 (0.10)
PKTP	49.3 (0.64)	56.4 (0.71)	65.6 (0.72)	74.2 (0.45)	83.0 (0.40)

超越 AIME

	@1	@2	@4	@8	@16
Random (Pass@k)	43.8 (0.00)	54.7 (0.00)	63.8 (0.00)	71.5 (0.00)	78.1 (0.00)
Linear Probe	46.0 (0.71)	56.8 (0.67)	65.7 (0.67)	74.1 (0.46)	81.1 (0.42)
RepExp	43.8 (0.16)	52.9 (0.14)	63.4 (0.12)	72.3 (0.13)	79.6 (0.12)
PKTP	43.8 (0.51)	53.9 (0.63)	62.7 (0.55)	72.2 (0.45)	80.9 (0.56)

奥数数学（简单）

	@1	@2	@4	@8	@16
Random (Pass@k)	54.7 (0.00)	69.9 (0.00)	81.4 (0.00)	88.7 (0.00)	92.9 (0.00)
Linear Probe	58.8 (0.61)	69.2 (0.59)	79.4 (0.50)	88.4 (0.48)	93.9 (0.20)
RepExp	54.9 (0.16)	66.1 (0.16)	75.4 (0.14)	83.2 (0.13)	89.9 (0.06)
PKTP	59.4 (0.53)	72.2 (0.61)	80.8 (0.42)	87.6 (0.32)	91.5 (0.24)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	41.2 (0.00)	52.5 (0.00)	62.8 (0.00)	72.1 (0.00)	80.6 (0.00)
Linear Probe	37.4 (0.38)	50.3 (0.39)	61.2 (0.47)	70.1 (0.32)	78.6 (0.35)
RepExp	41.2 (0.15)	51.8 (0.15)	65.0 (0.13)	72.1 (0.08)	81.9 (0.04)
PKTP	38.0 (0.59)	50.5 (0.49)	62.9 (0.66)	74.6 (0.45)	82.2 (0.30)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	44.7 (0.00)	56.7 (0.00)	67.2 (0.00)	75.9 (0.00)	83.6 (0.00)
Linear Probe	43.8 (0.80)	56.4 (0.82)	66.0 (0.55)	74.4 (0.51)	81.7 (0.59)
RepExp	45.0 (0.21)	55.9 (0.22)	69.0 (0.19)	77.5 (0.13)	85.7 (0.09)
PKTP	41.5 (0.80)	52.5 (0.79)	63.1 (0.78)	74.9 (0.52)	84.2 (0.41)

表 5: 每基准测试通过率 @k (%)，DeepSeek-R1-Distill-Qwen-1.5B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	31.8 (0.00)	42.5 (0.00)	53.1 (0.00)	63.4 (0.00)	73.2 (0.00)
Linear Probe	39.3 (0.55)	47.2 (0.41)	57.0 (0.57)	65.4 (0.59)	75.3 (0.50)
RepExp	31.9 (0.21)	38.9 (0.13)	50.2 (0.15)	63.1 (0.18)	73.8 (0.11)
PKTP	37.2 (0.67)	48.9 (0.84)	59.3 (0.73)	67.8 (0.63)	76.1 (0.42)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	27.0 (0.00)	37.1 (0.00)	47.5 (0.00)	57.3 (0.00)	66.9 (0.00)
Linear Probe	34.6 (0.92)	45.2 (0.73)	54.2 (0.62)	60.1 (0.50)	68.3 (0.65)
RepExp	26.8 (0.34)	36.1 (0.28)	47.7 (0.15)	54.0 (0.11)	67.0 (0.14)
PKTP	34.1 (0.73)	43.3 (0.72)	49.5 (0.69)	56.0 (0.65)	64.1 (0.72)

超越 AIME

	@1	@2	@4	@8	@16
Random (Pass@k)	16.2 (0.00)	24.6 (0.00)	34.5 (0.00)	45.9 (0.00)	58.4 (0.00)
Linear Probe	17.0 (0.34)	23.2 (0.57)	29.4 (0.74)	38.3 (0.69)	51.3 (0.67)
RepExp	16.0 (0.16)	22.5 (0.13)	31.8 (0.15)	45.9 (0.21)	62.1 (0.12)
PKTP	19.2 (0.55)	25.6 (0.61)	36.3 (0.64)	46.5 (0.54)	58.2 (0.89)

奥数数学（简单）

	@1	@2	@4	@8	@16
Random (Pass@k)	17.2 (0.00)	27.8 (0.00)	40.8 (0.00)	54.4 (0.00)	67.3 (0.00)
Linear Probe	16.1 (0.45)	27.5 (0.68)	41.0 (0.58)	50.9 (0.64)	62.8 (0.48)
RepExp	16.9 (0.22)	31.9 (0.21)	42.4 (0.19)	53.6 (0.15)	68.7 (0.12)
PKTP	18.5 (0.63)	29.0 (0.99)	41.9 (0.91)	55.7 (0.56)	69.9 (0.38)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	29.3 (0.00)	40.9 (0.00)	51.5 (0.00)	60.7 (0.00)	69.7 (0.00)
Linear Probe	32.5 (0.42)	42.3 (0.46)	52.0 (0.50)	62.3 (0.51)	72.3 (0.42)
RepExp	29.2 (0.14)	42.5 (0.16)	54.7 (0.12)	63.3 (0.10)	74.5 (0.07)
PKTP	31.4 (0.57)	44.9 (0.65)	57.8 (0.53)	65.2 (0.30)	71.1 (0.40)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	39.8 (0.00)	53.1 (0.00)	65.2 (0.00)	75.3 (0.00)	82.7 (0.00)
Linear Probe	40.4 (0.48)	52.0 (0.68)	63.0 (0.74)	74.2 (0.56)	83.4 (0.64)
RepExp	40.0 (0.19)	52.9 (0.16)	64.8 (0.12)	77.1 (0.13)	84.2 (0.10)
PKTP	40.6 (0.82)	53.7 (0.67)	66.6 (0.59)	77.5 (0.51)	85.5 (0.39)

表 6: 每基准通过率 @k (%)，Qwen3-8B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	70.2 (0.00)	80.6 (0.00)	86.3 (0.00)	90.1 (0.00)	93.1 (0.00)
Linear Probe	69.3 (0.64)	77.7 (0.50)	83.6 (0.34)	87.3 (0.32)	90.8 (0.38)
RepExp	70.0 (0.28)	80.9 (0.12)	86.6 (0.10)	91.0 (0.06)	92.8 (0.07)
PKTP	64.1 (0.69)	77.9 (0.55)	84.2 (0.43)	88.6 (0.43)	93.6 (0.41)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	46.2 (0.00)	56.3 (0.00)	65.3 (0.00)	73.1 (0.00)	80.3 (0.00)
Linear Probe	54.3 (0.57)	65.1 (0.61)	70.1 (0.57)	75.2 (0.33)	78.7 (0.33)
RepExp	46.3 (0.23)	56.5 (0.20)	65.5 (0.17)	74.9 (0.15)	84.3 (0.08)
PKTP	51.7 (0.68)	61.8 (0.49)	70.6 (0.54)	76.6 (0.59)	82.9 (0.50)

AMO-Bench

	@1	@2	@4	@8	@16
Random (Pass@k)	22.9 (0.00)	32.4 (0.00)	43.2 (0.00)	55.5 (0.00)	69.2 (0.00)
Linear Probe	25.7 (0.68)	34.1 (0.83)	47.2 (1.40)	57.8 (0.96)	71.0 (1.01)
RepExp	22.4 (0.30)	32.3 (0.35)	40.5 (0.33)	53.0 (0.29)	65.1 (0.26)
PKTP	27.2 (1.03)	37.9 (0.79)	48.4 (0.95)	60.5 (1.36)	73.8 (1.10)

奥数难题 (困难)

	@1	@2	@4	@8	@16
Random (Pass@k)	30.2 (0.00)	44.0 (0.00)	57.8 (0.00)	70.0 (0.00)	80.4 (0.00)
Linear Probe	31.9 (0.67)	44.1 (0.80)	57.9 (0.60)	70.3 (0.53)	82.2 (0.67)
RepExp	30.3 (0.23)	46.2 (0.19)	61.7 (0.16)	73.8 (0.11)	83.2 (0.10)
PKTP	33.5 (0.80)	45.9 (0.73)	59.3 (0.78)	69.7 (0.76)	79.3 (0.56)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	46.0 (0.00)	56.9 (0.00)	65.8 (0.00)	73.1 (0.00)	79.7 (0.00)
Linear Probe	45.3 (0.72)	54.4 (0.51)	61.7 (0.43)	68.5 (0.43)	75.7 (0.43)
RepExp	46.0 (0.19)	55.6 (0.15)	68.6 (0.12)	74.5 (0.11)	79.9 (0.08)
PKTP	45.5 (0.52)	56.5 (0.58)	64.5 (0.44)	71.3 (0.33)	77.7 (0.47)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	55.3 (0.00)	65.9 (0.00)	74.0 (0.00)	80.3 (0.00)	85.7 (0.00)
Linear Probe	60.9 (0.68)	70.9 (0.59)	77.8 (0.67)	82.7 (0.50)	86.5 (0.29)
RepExp	55.3 (0.15)	61.8 (0.16)	70.7 (0.14)	76.5 (0.08)	84.8 (0.08)
PKTP	53.9 (1.00)	64.0 (0.76)	77.3 (0.74)	85.0 (0.63)	89.8 (0.32)

表 7: 每基准测试通过率 @k (%)，OpenMath-Nemotron-7B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	68.7 (0.00)	80.0 (0.00)	87.0 (0.00)	91.7 (0.00)	95.2 (0.00)
Linear Probe	71.5 (0.67)	81.8 (0.47)	86.8 (0.35)	90.5 (0.35)	93.8 (0.35)
RepExp	69.1 (0.25)	81.1 (0.16)	89.6 (0.12)	93.5 (0.09)	98.1 (0.05)
PKTP	72.1 (0.71)	82.9 (0.29)	87.6 (0.31)	90.6 (0.45)	94.3 (0.42)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	41.4 (0.00)	52.3 (0.00)	62.9 (0.00)	73.1 (0.00)	82.4 (0.00)
Linear Probe	43.0 (0.50)	52.6 (0.70)	63.4 (0.46)	72.4 (0.40)	80.7 (0.63)
RepExp	41.4 (0.28)	54.1 (0.25)	62.5 (0.18)	73.6 (0.11)	83.6 (0.09)
PKTP	47.0 (0.68)	58.7 (0.88)	67.9 (0.55)	77.8 (0.44)	83.9 (0.51)

AMO-Bench

	@1	@2	@4	@8	@16
Random (Pass@k)	16.9 (0.00)	27.0 (0.00)	38.9 (0.00)	51.2 (0.00)	63.6 (0.00)
Linear Probe	18.8 (1.35)	29.2 (1.13)	41.8 (1.44)	54.0 (0.82)	66.3 (0.80)
RepExp	17.1 (0.35)	34.0 (0.33)	43.1 (0.28)	55.7 (0.27)	71.0 (0.19)
PKTP	20.5 (0.78)	27.0 (0.76)	35.5 (1.06)	47.7 (1.11)	67.7 (1.14)

奥数难题 (困难)

	@1	@2	@4	@8	@16
Random (Pass@k)	24.5 (0.00)	36.9 (0.00)	50.4 (0.00)	63.1 (0.00)	73.7 (0.00)
Linear Probe	28.7 (0.87)	42.4 (0.68)	55.9 (0.68)	68.2 (0.52)	77.2 (0.51)
RepExp	24.4 (0.23)	38.6 (0.21)	53.3 (0.16)	67.1 (0.13)	75.4 (0.10)
PKTP	29.7 (0.75)	43.6 (0.90)	55.3 (0.65)	67.5 (0.45)	77.4 (0.50)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	47.4 (0.00)	59.1 (0.00)	69.6 (0.00)	78.7 (0.00)	86.1 (0.00)
Linear Probe	47.1 (0.36)	58.9 (0.48)	69.3 (0.41)	77.9 (0.39)	85.6 (0.29)
RepExp	47.2 (0.17)	57.9 (0.11)	65.8 (0.10)	77.4 (0.07)	87.4 (0.06)
PKTP	48.1 (0.44)	60.9 (0.57)	71.9 (0.61)	80.1 (0.43)	87.1 (0.22)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	49.5 (0.00)	61.1 (0.00)	70.6 (0.00)	78.3 (0.00)	84.9 (0.00)
Linear Probe	55.5 (0.82)	65.2 (0.75)	73.3 (0.50)	82.0 (0.55)	87.2 (0.35)
RepExp	49.6 (0.17)	64.1 (0.18)	74.0 (0.11)	78.9 (0.11)	83.9 (0.10)
PKTP	54.4 (0.81)	64.5 (0.65)	71.1 (0.43)	78.2 (0.54)	84.5 (0.42)

表 8: 每基准通过率 @k (%)，DeepSeek-R1-Distill-Qwen-7B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	52.7 (0.00)	66.5 (0.00)	76.9 (0.00)	83.5 (0.00)	88.2 (0.00)
Linear Probe	51.6 (0.58)	65.4 (0.47)	75.1 (0.44)	80.9 (0.35)	87.4 (0.60)
RepExp	52.3 (0.25)	65.0 (0.25)	77.1 (0.16)	87.2 (0.09)	90.5 (0.04)
PKTP	55.2 (0.87)	68.6 (0.57)	78.1 (0.40)	86.1 (0.45)	90.2 (0.33)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	38.1 (0.00)	47.0 (0.00)	55.7 (0.00)	65.4 (0.00)	75.4 (0.00)
Linear Probe	41.5 (0.40)	45.4 (0.38)	51.7 (0.68)	62.3 (0.59)	77.1 (0.71)
RepExp	38.0 (0.16)	46.1 (0.20)	55.0 (0.22)	68.7 (0.19)	80.2 (0.10)
PKTP	41.0 (0.73)	48.6 (0.76)	57.9 (0.82)	68.3 (0.63)	77.5 (0.65)

AMO-Bench

	@1	@2	@4	@8	@16
Random (Pass@k)	7.0 (0.00)	12.5 (0.00)	21.1 (0.00)	33.3 (0.00)	48.8 (0.00)
Linear Probe	6.3 (0.59)	12.4 (0.79)	23.7 (1.11)	42.0 (1.52)	57.6 (1.26)
RepExp	7.4 (0.36)	12.2 (0.39)	26.2 (0.50)	41.7 (0.31)	60.4 (0.24)
PKTP	10.7 (1.32)	20.0 (1.82)	33.9 (1.40)	49.3 (1.45)	62.4 (1.27)

奥数难题 (困难)

	@1	@2	@4	@8	@16
Random (Pass@k)	11.5 (0.00)	19.2 (0.00)	29.9 (0.00)	43.3 (0.00)	57.9 (0.00)
Linear Probe	13.7 (0.53)	21.2 (0.60)	28.0 (0.42)	37.7 (0.65)	52.7 (0.73)
RepExp	11.6 (0.18)	19.2 (0.20)	27.8 (0.17)	39.5 (0.16)	60.6 (0.10)
PKTP	10.6 (0.46)	20.3 (0.56)	29.4 (0.54)	43.4 (0.73)	58.0 (0.59)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	41.6 (0.00)	53.1 (0.00)	63.3 (0.00)	72.8 (0.00)	81.5 (0.00)
Linear Probe	40.6 (0.35)	50.2 (0.60)	60.5 (0.48)	70.6 (0.41)	80.8 (0.34)
RepExp	41.4 (0.14)	51.5 (0.11)	64.0 (0.12)	74.4 (0.08)	80.4 (0.04)
PKTP	42.8 (0.64)	54.0 (0.54)	64.4 (0.54)	74.0 (0.53)	83.5 (0.36)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	50.2 (0.00)	63.3 (0.00)	74.4 (0.00)	83.3 (0.00)	89.9 (0.00)
Linear Probe	47.2 (0.89)	59.3 (0.80)	73.3 (0.64)	82.1 (0.51)	87.8 (0.40)
RepExp	50.1 (0.30)	61.8 (0.22)	74.6 (0.17)	85.8 (0.11)	92.3 (0.03)
PKTP	49.4 (0.71)	61.7 (0.87)	73.0 (0.43)	81.1 (0.43)	89.2 (0.35)

表 9: 每基准通过率 @k (%)，Skywork-OR1-Math-7B。

美国数学邀请赛

	@1	@2	@4	@8	@16
Random (Pass@k)	59.7 (0.00)	71.2 (0.00)	79.1 (0.00)	84.7 (0.00)	89.2 (0.00)
Linear Probe	62.3 (0.73)	70.7 (0.67)	80.2 (0.44)	85.3 (0.37)	89.8 (0.29)
RepExp	59.7 (0.23)	73.2 (0.16)	82.0 (0.12)	85.4 (0.08)	92.8 (0.08)
PKTP	63.6 (0.89)	75.4 (0.49)	80.6 (0.46)	84.6 (0.27)	88.4 (0.45)

哈佛-麻省理工数学竞赛

	@1	@2	@4	@8	@16
Random (Pass@k)	35.8 (0.00)	43.8 (0.00)	52.3 (0.00)	61.7 (0.00)	71.7 (0.00)
Linear Probe	40.3 (0.47)	48.2 (0.57)	54.5 (0.63)	62.5 (0.48)	70.8 (0.45)
RepExp	35.8 (0.18)	41.9 (0.20)	50.5 (0.16)	64.0 (0.13)	70.6 (0.10)
PKTP	37.1 (0.63)	46.2 (0.64)	56.1 (0.79)	64.8 (0.78)	71.5 (0.45)

AMO-Bench

	@1	@2	@4	@8	@16
Random (Pass@k)	11.9 (0.00)	18.7 (0.00)	26.5 (0.00)	35.0 (0.00)	45.0 (0.00)
Linear Probe	11.7 (0.84)	17.6 (0.80)	23.7 (0.74)	29.3 (0.76)	41.3 (0.92)
RepExp	12.1 (0.40)	21.7 (0.24)	30.9 (0.23)	38.4 (0.35)	53.1 (0.24)
PKTP	12.8 (0.97)	22.8 (1.30)	32.2 (1.15)	43.0 (1.44)	61.1 (1.65)

奥数难题 (困难)

	@1	@2	@4	@8	@16
Random (Pass@k)	19.7 (0.00)	31.0 (0.00)	44.5 (0.00)	58.6 (0.00)	72.2 (0.00)
Linear Probe	19.0 (0.52)	28.5 (0.67)	39.8 (0.72)	55.6 (0.92)	72.1 (0.89)
RepExp	19.9 (0.18)	30.6 (0.23)	44.2 (0.20)	52.3 (0.14)	64.3 (0.20)
PKTP	20.4 (0.61)	31.7 (0.96)	45.6 (0.93)	58.0 (0.64)	72.2 (0.62)

Omni-MATH

	@1	@2	@4	@8	@16
Random (Pass@k)	50.2 (0.00)	61.4 (0.00)	70.7 (0.00)	78.8 (0.00)	85.6 (0.00)
Linear Probe	53.5 (0.60)	63.6 (0.40)	71.8 (0.42)	79.9 (0.41)	85.1 (0.32)
RepExp	50.1 (0.21)	63.5 (0.12)	73.4 (0.12)	81.5 (0.08)	84.8 (0.08)
PKTP	52.1 (0.63)	63.3 (0.41)	74.5 (0.38)	81.1 (0.42)	84.5 (0.26)

RIMO-N

	@1	@2	@4	@8	@16
Random (Pass@k)	53.1 (0.00)	65.1 (0.00)	74.6 (0.00)	82.4 (0.00)	89.2 (0.00)
Linear Probe	53.1 (0.61)	67.2 (0.58)	76.7 (0.51)	82.8 (0.45)	88.9 (0.46)
RepExp	53.1 (0.25)	69.5 (0.16)	78.4 (0.16)	83.4 (0.11)	90.3 (0.11)
PKTP	57.0 (1.01)	68.9 (0.82)	77.5 (0.60)	83.5 (0.59)	89.0 (0.46)

E 不同池大小的结果

本节对其他池大小重复 Fig. 3，$N \in \{32, 48, 64, 80, 96, 112\}$，其中每个问题的池均来自其 128 生成的轨迹，且截止值为 $T = 4000$，与主情景一致。

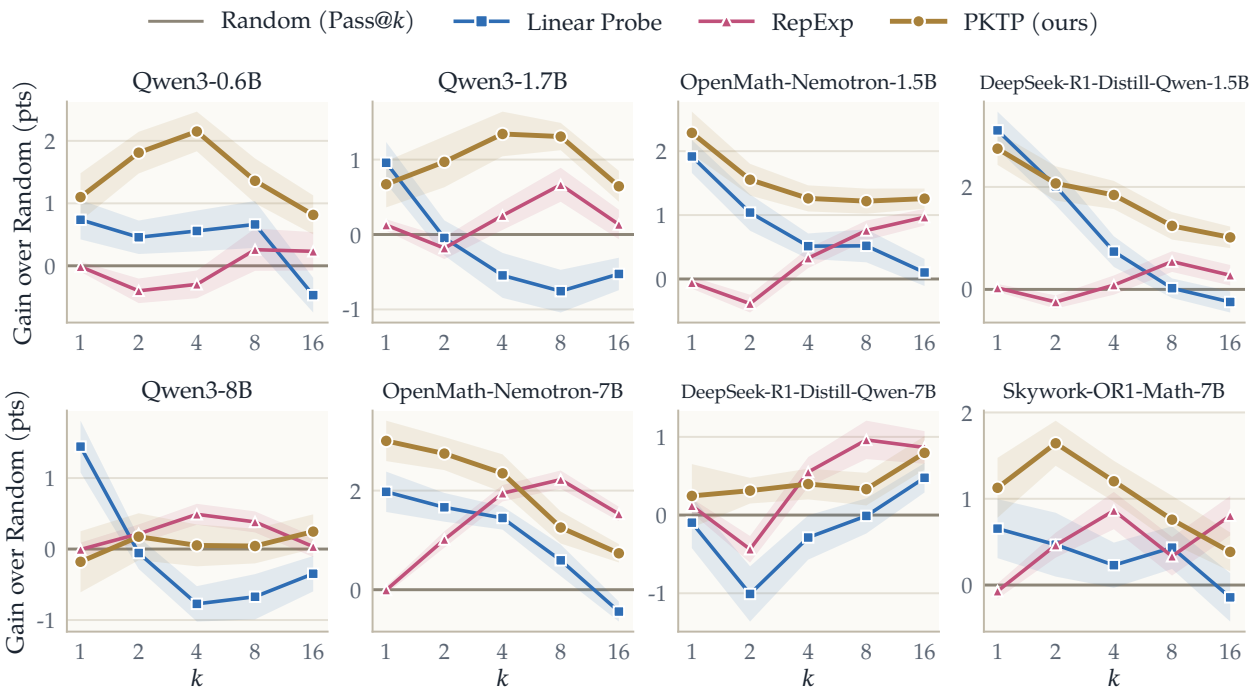


图 8: **相较于随机剪枝在** pass@k **上的提升，使用** $N = 32$ 。如 Fig. 3 所示，从每个问题生成的 128 中抽取 $N = 32$ 个回溯路径作为候选池，并结合 $T = 4000$ 。

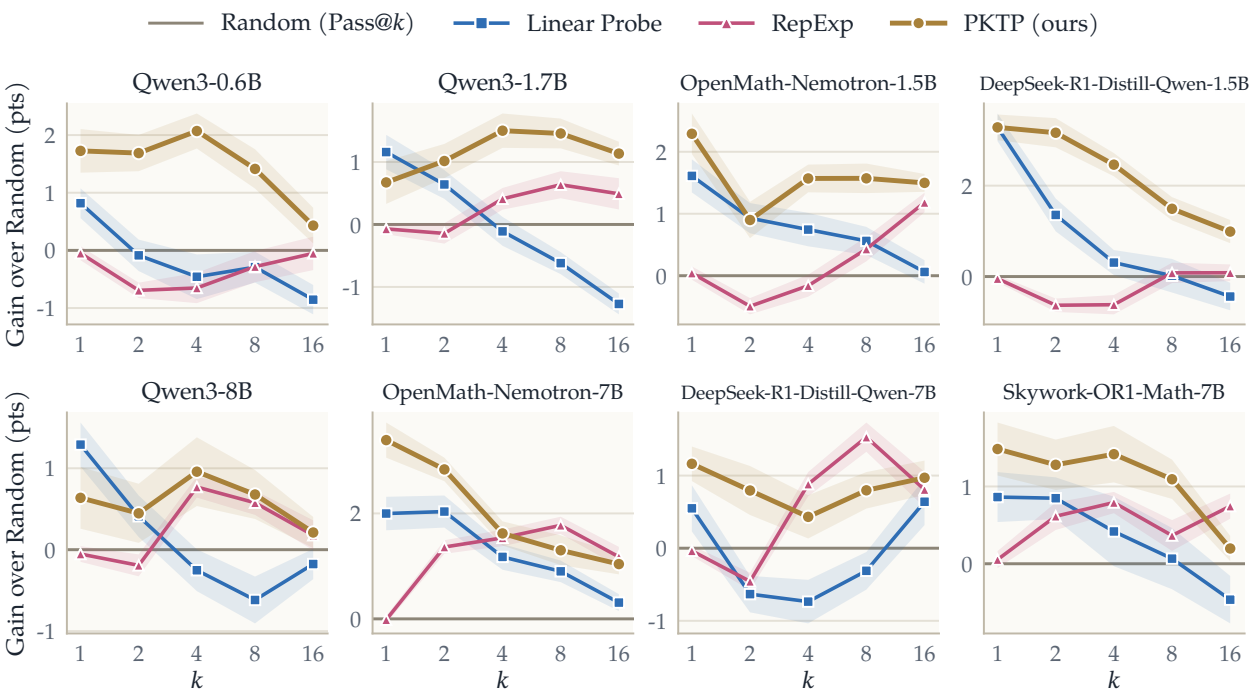


图 9: **相较于随机剪枝在** pass@k **上的收益，使用** $N = 48$ 。与 Fig. 3 类似，从每个问题生成的 128 中抽取 $N = 48$ 条轨迹组成池，并进行 $T = 4000$ 。

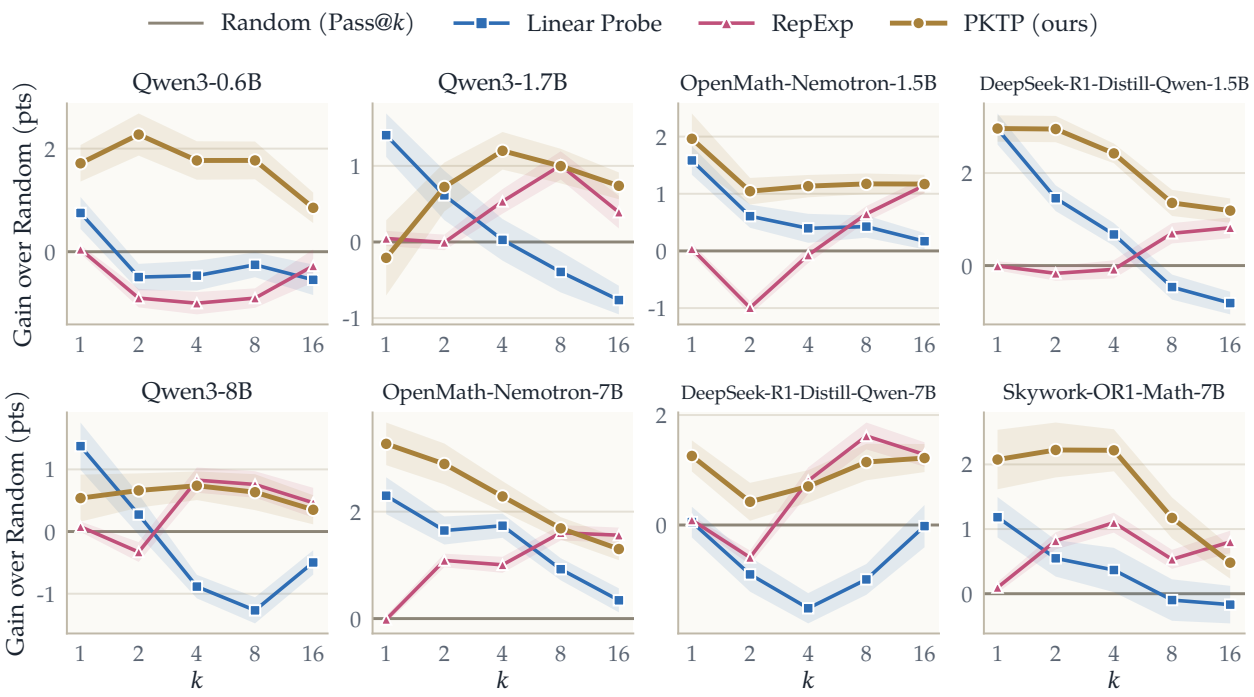


图 10: **相较于随机剪枝在** pass@k **上的提升，使用** $N = 64$ 。如 Fig. 3 所示，从每个问题生成的 128 中抽取 $N = 64$ 条轨迹作为候选池，并结合 $T = 4000$ 。

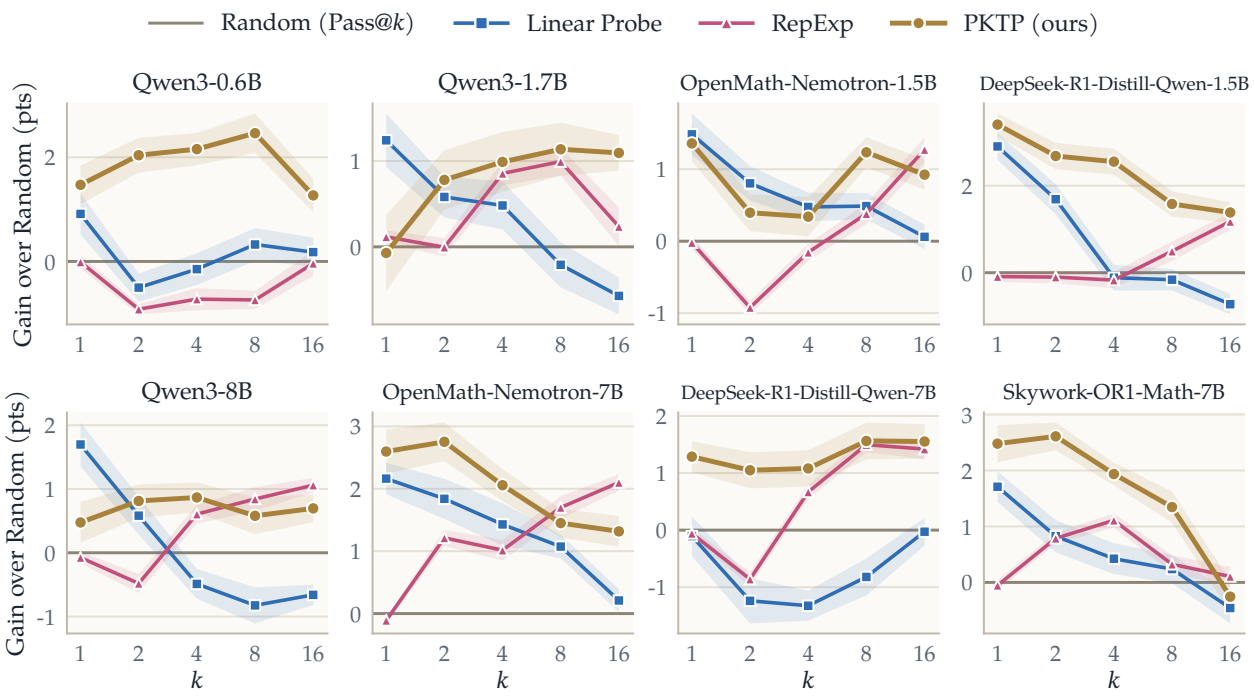


图 11: **在 pass@k 上相对于使用 $N = 80$ 的随机剪枝的增益**。与 Fig. 3 中相同，从为每个问题生成的 128 中抽取 $N = 80$ 次 rollout 构成一个池，并采用 $T = 4000$。

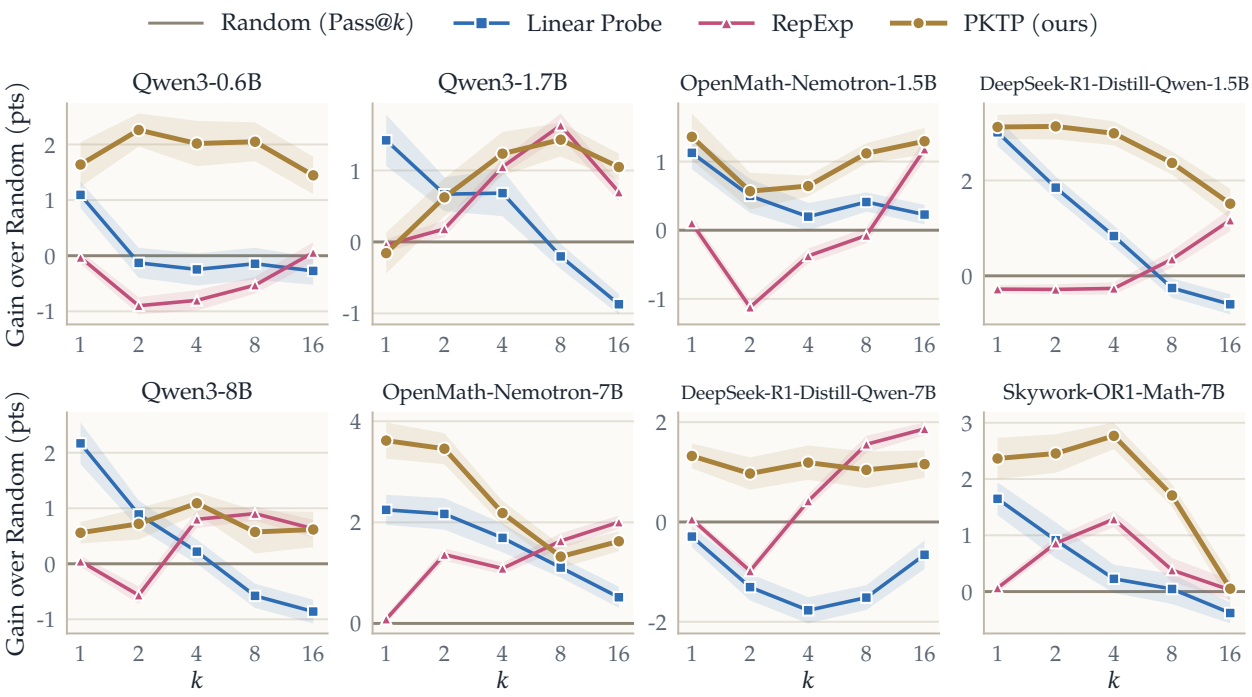


图 12: **相较于随机剪枝在** pass@k **上的收益，使用** $N = 96$ 。如 Fig. 3 所示，从每个问题生成的 128 中抽取 $N = 96$ 个回溯路径作为池，并结合 $T = 4000$ 。

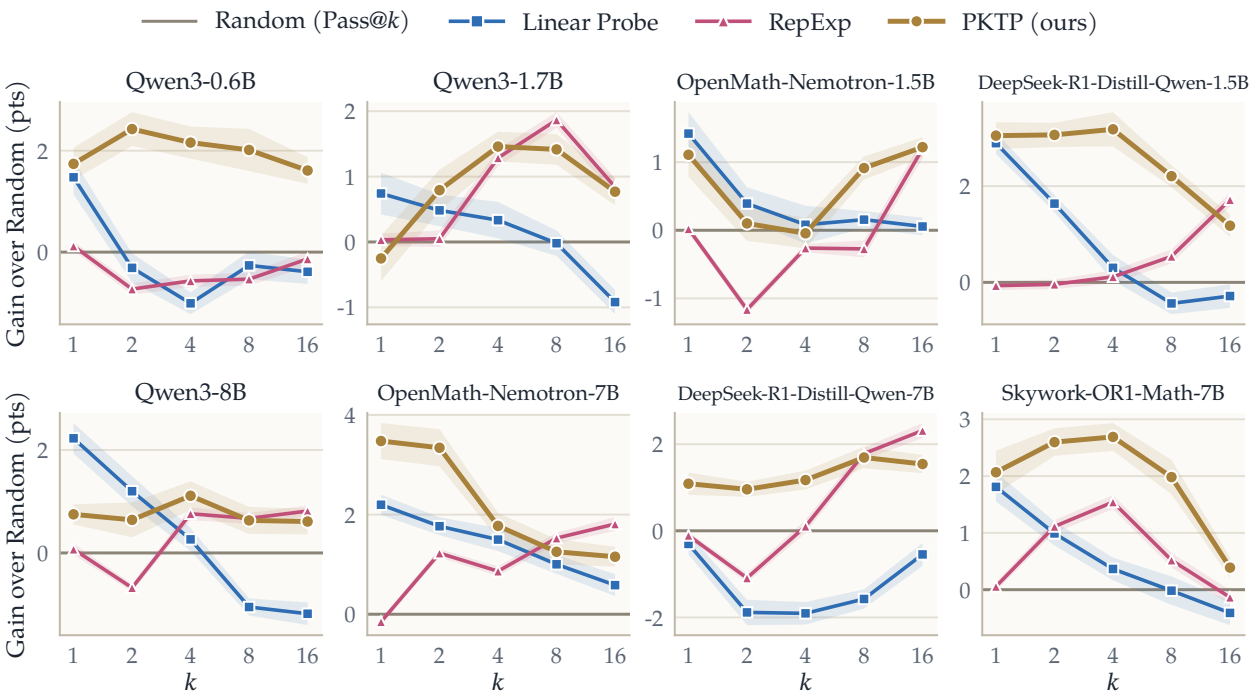


图 13: **相较于随机剪枝在 pass@k 上的收益，使用 $N = 112$** 。与 Fig. 3 相同，使用一个包含 $N = 112$ 次回溯的池，这些回溯是从每个问题生成的 128 和 $T = 4000$ 得到的。

F 表示细节

对于每次 rollout，令 $x_t \in \mathbb{R}^d$ 为模型在第 t 个生成 token 处的最后一个 Transformer 块的隐状态，其中 d 为模型的隐状态大小：Qwen3-0.6B 为 1024，Qwen3-1.7B 为 2048，Qwen3-8B 为 4096，OpenMath-Nemotron-1.5B 和 DeepSeek-R1-Distill-Qwen-1.5B 为 1536，OpenMath-Nemotron-7B、DeepSeek-R1-Distill-Qwen-7B 和 Skywork-OR1-Math-7B 为 3584。指数移动平均（EMA）遵循 $e_t = (1-\alpha)\, e_{t-1} + \alpha\, x_t$，其中 $\alpha = 10^{-3}$；h_i 是 e_t 在前 T 个生成 token 之后的规范化值，或对于在截断点之前结束的 rollout，则为所有生成 token 之后的规范化值。

G 扩展的相关工作

测试时剪枝展开。 测试时缩放为每个问题生成多个回溯路径并进行聚合 [3, 35, 44, 48]，越来越多的研究工作通过提前停止无希望的回溯路径来节省计算量。其中一类方法利用模型自身的置信度，例如 token 级别的置信度或其对成功可能性的自我估计，来决定保留哪些回溯路径 [13, 30]。另一类方法使用奖励模型 [36] 对部分回溯路径进行评分，或通过对隐状态进行探测 [1, 25, 54] 来评分。Yang et al. [51] 同时利用此类探测在部分回溯路径上进行束搜索，剪枝表现较差的路径，并从最佳前缀分支出新的回溯路径。所有这些方法都独立地对每条回溯路径进行评分，并保留得分最高的路径，这是纯粹利用（exploitation）的极端情况 Section 2。在另一极端，RepExp [39] 选择那些表示尚未被已选路径充分解释的回溯路径，而不考虑其质量。PKTP 介于两者之间，因为它建模了回溯路径结果之间的依赖关系，并选择预测 pass@k 最高的集合。

Pass@k 作为目标。 Pass@k 是推理和代码生成的标准评估指标，已有若干工作在训练过程中优化该指标。Walder and Karkhanis [41] 推导了针对 pass@k 的低方差策略梯度估计量，Chen et al. [8] 使用 pass@k 作为奖励以平衡探索与利用，Chow et al. [10] 对模型进行微调以实现最佳的 N 推理。Chen et al. [7] 同时奖励一组响应的质量与多样性，通过其相似度矩阵的行列式来衡量多样性。这些方法均为后训练方法，而 PKTP 保持模型不变，并在推理时通过选择继续哪些部分回溯路径来优化 pass@k 。与此同时，Wu et al. [47] 也保持推理模型不变，但使用 pass@k 作为奖励来训练一个规划器，该规划器为每次回溯路径生成不同的大纲后再进行生成。因此，他们改变了回溯路径的采样方式，而 PKTP 将 N 独立采样的部分回溯路径视为给定，并选择其中 k 个继续推进。

相关目标：至少实现一次成功。 同样的目标在信息检索中表现为期望的 1-call@k，即前 k 个文档中至少有一个相关文档的概率。Chen and Karger [6] 采用贪心方式优化它，并且 Sanner et al. [34] 证明在相关性的潜在子主题模型下进行贪心优化会生成多样化的排序结果，这与我们的潜在因子导致多样化的保留集合具有相同的效果。在贝叶斯优化中，批量改进概率是指批量中的至少一个点优于当前最优解的概率，该概率是单调且拟凹的，因此可以采用贪心方式最大化 [32, 46]。其他方法通过手动设定权衡来平衡质量与多样性，例如最大边际相关性 [5] 和行列式点过程 [22]。与这些工作不同，PKTP 适用于部分推理回溯，从其表示中学习其结果的联合分布，并优化一个保持确切目标拟凹性质的闭式代理函数。